LAPORAN PELAKSANAAN
MERDEKA BELAJAR KAMPUS MERDEKA (MBKM)
BADAN RISET DAN INOVASI NASIONAL
SEMESTER GENAP 2025/2026

ANALISIS SENTIMEN PEMBERITAAN PENYAKIT MENULAR PADA PORTAL BERITA ONLINE MENGGUNAKAN INDOBERT-CNN-BILSTM

PENELITIAN/RISET

Disusun oleh:

Nama	**: Aulia Kartika Putri**
NIM	**: 235150207111033**
Prodi/Jurusan	**: Teknik Informatika**
Fakultas	**: Fakultas Ilmu Komputer**
Universitas	**: Universitas Brawijaya**
Pembimbing	**: 1. Andri Fachrur Rozie, SKom., M.Eng.**
	2. Yuita Arum Sari, S.Kom., M.Kom., Ph.D.

PUSAT RISET SAINS DATA DAN INFORMASI
BADAN RISET DAN INOVASI NASIONAL
BANDUNG
2026

LEMBAR PENGESAHAN LAPORAN PELAKSANAAN MERDEKA BELAJAR KAMPUS MERDEKA (MBKM) BADAN RISET DAN INOVASI NASIONAL SEMESTER GENAP 2025/2026

ANALISIS SENTIMEN PEMBERITAAN PENYAKIT MENULAR PADA PORTAL BERITA ONLINE MENGGUNAKAN INDOBERT-CNN-BILSTM

PENELITIAN/RISET

Disusun oleh:

Nama	**: Aulia Kartika Putri**
NIM	**: 235150207111033**
Prodi/Jurusan	**: Teknik Informatika**
Fakultas	**: Fakultas Ilmu Komputer**
Universitas	**: Universitas Brawijaya**
Unit Kerja BRIN	**: Pusat Riset Sains Data dan Informasi**

Bandung, 15 Juli 2026	
Menyetujui, **Pembimbing BRIN** TT ELEKTRONIK **Andri Fachrur Rozie, SKom., M.Eng.** **NIP 198510102008121002**	**Mengetahui,** **Pembimbing Perguruan Tinggi** **Yuita Arum S Kom., Ph.D.** **NIK 2016098807152001**

Dokumen ini ditandatangani secara elektronik menggunakan sertifikat dari BSrE, silahkan lakukan verifikasi pada dokumen elektronik yang dapat diunduh dengan melakukan scan QR Code

DAFTAR ISI

DAFTAR ISI **3**
DAFTAR GAMBAR **5**
DAFTAR TABEL **7**
BAB I **9**
PENDAHULUAN **9**
1.1 Latar Belakang 9
1.2 Tujuan Kegiatan MBKM 11
1.3 Sasaran Kegiatan MBKM 11
BAB II **11**
PROFIL MITRA KEGIATAN MBKM **12**
2.1 Sejarah Badan Riset dan Inovasi Nasional 12
2.2 Struktur Organisasi Badan Riset dan Inovasi Nasional 13
2.3 Visi dan Misi Tujuan dan Sasaran Strategis Badan Riset dan Inovasi Nasional 15
2.4 Profil Satuan Kerja Tempat Pelaksanaan MBKM 16
2.5 Profil Kelompok Penelitian/Fungsi Kerja Tempat Pelaksanaan MBKM 18
BAB III **19**
PELAKSANAAN KEGIATAN MBKM **20**
3.1 Uraian Umum Kegiatan MBKM yang Dilakukan 20
3.2 Keterlibatan Penelitian/Riset atau Magang/Praktik Kerja yang Dilakukan 20
3.2.1 Data Epidemi 21
3.2.2 Data Preprocessing 22
3.2.3 Stratified K-Fold 23
3.2.4 Representasi Vektor (Embedding) 24
3.2.5 Penanganan Ketidakseimbangan Data (Undersampling) 24
3.2.6 Modelling 26
3.2.7 Evaluation Matrix 28
3.2.7.1 Accuracy 29
3.2.7.2 Precision 29
3.2.7.3 Recall 29
3.2.7.4 F1-Score 29
3.2.7.5 AUC-ROC 30
3.3 Penugasan-Penugasan yang Telah Diselesaikan 31
3.4 Pembelajaran Hal Baru (Lessons Learned) yang Diperoleh 34
BAB IV **35**
PENUTUP **36**
4.1 Kesimpulan 36
4.2 Saran 37
DAFTAR PUSTAKA **38**

LAMPIRAN.....40

DAFTAR GAMBAR

Gambar 2.1 Struktur Organisasi BRIN..... 14
Gambar 2.2 Profil Pusat Riset Sains Data dan Informasi (Organisasi Riset Elektronika dan Informatika)..... 18
Gambar 2.3 Alur Kerja Pusat Riset Sains Data dan Informasi..... 18
Gambar 2.4 Profil Kelompok Riset Information Retrieval (Pusat Riset Sains Data dan Informasi)..... 19
Gambar 3.1 Keterlibatan Riset/Penelitian yang Dilakukan..... 22
Gambar 3.2 Berita online mengenai covid-19..... 23
Gambar 3.3 Arsitektur IndoBERT..... 28
Gambar 3.4 Arsitektur CNN 1-D..... 29
Gambar 3.5 Arsitektur BiLSTM..... 29
Gambar 3.6 Sertifikat Pelatihan Pengantar MBKM BRIN..... 33
Gambar 3.7 Daftar Mata Pelatihan Pengantar MBKM BRIN..... 33
Gambar 5.1 Pertemuan Pengantar MBKM..... 43
Gambar 5.2 Perkenalan Mahasiswa Pusat Riset Sains Data dan Informasi.....43
Gambar 5.3 Penjelasan Mengenai Penelitian Information Retrieval..... 44
Gambar 5.4 Mengikuti Pelatihan Safety Induction.....44
Gambar 5.5 Mengikuti Kegiatan Webinar DESAIN 1.....45
Gambar 5.6 Pertemuan Mingguan dengan Pembimbing..... 45
Gambar 5.7 Pertemuan Mingguan dengan Pembimbing..... 46
Gambar 5.8 Pertemuan Progress Mingguan dengan Tim Online News.....46
Gambar 5.9 Pertemuan Progress Mingguan dengan Tim Online News.....47
Gambar 5.10 Pertemuan Progress Mingguan dengan Tim Information Retrieval.....47
Gambar 5.11 Pertemuan Progress Mingguan dengan Tim Online News.....48
Gambar 5.12 Mengikuti Webinar DESAIN 3..... 48
Gambar 5.13 Pertemuan Progress Mingguan dengan Tim Online News.....49
Gambar 5.14 Class Tambahan Belajar GIT..... 49
Gambar 5.15 Pertemuan Progress Mingguan dengan Tim Online News.....50
Gambar 5.16 Mengikuti Webinar DESAIN 4..... 50
Gambar 5.17 Pertemuan Progress Mingguan dengan Tim Online News.....51
Gambar 5.18 Pertemuan Progress Mingguan dengan Tim Online News.....51
Gambar 5.19 Pertemuan Progress Mingguan dengan Tim Online News.....52
Gambar 5.20 Pertemuan Progress Mingguan.....52
Gambar 5.21 Presentasi Akhir..... 53

DAFTAR TABEL

Tabel 3.1 Sampel klasifikasi data Epidemi.....22
Tabel 3.2 Perbandingan Hasil Evaluasi Metrik.....30
Tabel 3.3 Hasil AUC-ROC..... 30

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi informasi dan komunikasi di era digitalisasi telah membawa perubahan dalam cara memproduksi, mendistribusikan, dan mengkonsumsi informasi. Perubahan dari media konvensional menuju platform digital membuat persebaran dan aliran informasi menjadi sangat cepat, masif, dan tanpa batas. Kondisi ini mendorong internet menjadi sumber utama masyarakat dalam memperoleh informasi sehari-hari, termasuk berbagai berita dan perkembangan isu terkini. Berdasarkan survei yang dilakukan oleh Asosiasi Penyelenggara Jasa Internet Indonesia (APJII), tingkat penetrasi internet di Indonesia mencapai 80,66% pada tahun 2025. Tingginya penggunaan internet menunjukkan bahwa masyarakat semakin bergantung pada platform digital sebagai media utama dalam mengakses informasi. Penyebaran informasi yang terus berlangsung kemudian menghasilkan data dalam jumlah besar yang terus bertambah dan membentuk kumpulan data besar (big data) yang menyimpan berbagai informasi yang memiliki makna.

Salah satu bentuk informasi yang mengalami pertumbuhan yang pesat adalah berita daring (*online*). Kemudahan dalam penyebaran portal berita digital menyebabkan penyebaran informasi menjadi masif dan *real-time*. Kondisi ini memberikan kemudahan bagi masyarakat dalam memperoleh informasi secara tepat. Namun, tingginya intensitas penyebaran informasi juga menimbulkan tantangan, terutama ketika informasi yang disebarkan berkaitan dengan isu sensitif yang memiliki dampak langsung ke masyarakat. Salah satu isu yang krusial adalah pemberitaan mengenai penyakit menular. Informasi mengenai wabah, penyebaran penyakit, dan kondisi masyarakat dapat mempengaruhi cara masyarakat memahami suatu situasi kesehatan, sehingga penyampaian berita menjadi faktor penting yang perlu diperhatikan.

Pemberitaan mengenai penyakit menular tidak selalu disampaikan secara netral. Pemilihan kata, gaya bahasa jurnalistik, dan sudut pandang dalam

penyajian berita sering mengandung kecenderungan sentimen tertentu, baik positif, negatif, dan netral. Penyebaran berita dengan dominasi sentimen negatif akan menimbulkan kepanikan, kecemasan, serta dapat mempengaruhi opini masyarakat terhadap situasi kesehatan. Namun, penyebaran informasi yang lebih seimbang dapat membantu masyarakat dalam memahami situasi secara lebih objektif. Oleh karena itu, diperlukan suatu pendekatan yang dapat mengidentifikasi kecenderungan sentimen dalam berita online agar pola penyebaran informasi dapat dipahami secara lebih komprehensif.

Pendekatan yang digunakan untuk permasalahan tersebut adalah analisis sentimen. Analisis sentimen merupakan sebuah cabang dari pemrosesan bahasa alami (*Natural Language Processing*) yang berfokus pada identifikasi, ekstraksi, dan klasifikasi opini, sentimen, atau emosi dalam teks ke dalam kategori positif, negatif, atau netral (Pang dan Lee, 2008 ; Liu, 2012). Hasil analisis sentimen ini dapat dimanfaatkan oleh pemerintah dan media online sebagai bahan evaluasi untuk mengetahui kecenderungan pemberitaan yang tersebar di masyarakat, sehingga penyebaran informasi berita tidak menimbulkan dampak negatif yang berlebih. Selain itu, hasil analisis sentimen ini juga dapat mendukung pengembangan website Pantau Tular yang sedang dikembangkan oleh Badan Riset dan Inovasi Nasional (BRIN) sebagai platform pemantauan informasi terkait penyakit menular di ruang digital.

Penerapan analisis sentimen pada berita online bahasa Indonesia mengalami beberapa tantangan. Salah satu tantangan utamanya adalah ketidakseimbangan distribusi data atau *class imbalance.* Permasalahan ini merupakan sebuah kondisi ketika jumlah data pada suatu kelas sentimen jauh lebih dominan dibandingkan dengan kelas lainnya. Kondisi ini dapat menyebabkan model klasifikasi cenderung bias terhadap kelas mayoritas sehingga kemampuan model dalam mengenali kelas minoritas menjadi kurang optimal. Mengatasi permasalahan tersebut diperlukan teknik *preprocessing* yang mampu menghasilkan distribusi data yang seimbang. Pendekatan yang digunakan adalah teknik *undersampling*. Teknik *undersampling* merupakan sebuah teknik yang menyeimbang dataset dengan cara membuang atau mengurangi sebagian sampel dari kelas mayoritas (Kaur et al., 2019). Di dalam

penelitian ini terdapat tiga metode undersampling yang digunakan yaitu RUS (*Random Sampling*), OSS (*One-Sided Selection*), NCR (*Neighbourhood Cleaning Rule*).

Selain permasalahan distribusi data, tantangan yang dihadapi adalah menentukan metode klasifikasi yang mampu memberikan performa terbaik dalam memahami kompleksitas bahasa pada teks berita, khususnya dalam penggunaan istilah medis dan konteks semantik. Oleh karena itu, penelitian ini mengusulkan penggunaan model gabungan dari IndoBERT-CNN-BiLSTM. Melalui kombinasi ketiga model tersebut dan metode imbalance data, penelitian ini menemukan metode analisis sentimen yang optimal dalam mengklasifikasikan sentimen berita online mengenai penyakit menular.

1.2 Tujuan Kegiatan MBKM

1. Menganalisis pengaruh metode Undersampling dalam mengatasi class imbalance pada dataset berita penyakit menular.
2. Membandingkan performa model hibrida IndoBERT-CNN-BiLSTM dengan dan tanpa penerapan Undersampling dalam klasifikasi sentimen.

1.3 Sasaran Kegiatan MBKM

1. Memperoleh hasil analisis mengenai pengaruh metode undersampling dalam mengatasi *class imbalance* pada dataset berita penyakit menular.
2. Memperoleh perbandingan performa model hibrida IndoBERT-CNN-BiLSTM dengan dan tanpa penerapan *undersampling* dalam klasifikasi sentimen.

BAB II
PROFIL MITRA KEGIATAN MBKM

2.1 Sejarah Badan Riset dan Inovasi Nasional

Badan Riset dan Inovasi Nasional (BRIN) saat ini merupakan satu-satunya badan penelitian nasional berdasarkan Peraturan Presiden Nomor 33 Tahun 2021. Berdasarkan modul yang ditulis oleh Pusat Pengembangan Kompetensi BRIN (2021), lembaga ini pertama kali dibentuk oleh Presiden Joko Widodo pada tahun 2019 untuk mendukung Undang-Undang Nomor 11 Tahun 2019 tentang Sistem Nasional Ilmu Pengetahuan dan Teknologi (UU SISNAS IPTEK). Mulanya BRIN melekat dengan Kementerian Riset dan Teknologi (Kemenristek) dimana Menteri Riset dan Teknologi sekaligus menjadi kepala BRIN.

Pada tanggal 28 April 2021 BRIN telah berdiri sendiri serta bertanggung jawab langsung kepada Presiden yang berarti telah terpisah dari Kemenristek. Saat ini seluruh badan penelitian nasional Indonesia bergabung menjadi BRIN. Badan penelitian tersebut diantaranya adalah Lembaga Ilmu Pengetahuan Indonesia (LIPI), Badan Pengkajian dan Penerapan Teknologi (BPPT), Badan Tenaga Nuklir Nasional (BATAN), dan Lembaga Penerbangan dan Antariksa Nasional (LAPAN).

Berdasarkan Peraturan Presiden Republik Indonesia Nomor 78 Tahun 2021 mengenai BRIN adalah lembaga pemerintah yang berada di bawah dan bertanggung jawab langsung kepada Presiden dalam menyelenggarakan penelitian, pengembangan, pengkajian dan penerapan, serta invensi dan inovasi, penyelenggaraan keantariksaan yang terintegrasi. Dalam Peraturan Presiden tersebut BRIN terdiri dari Organisasi Riset (OR) dan Badan Riset dan Inovasi Daerah (BRIDA). OR merupakan organisasi nonstruktural yang menyelenggarakan teknis penelitian, pengembangan, pengkajian dan penerapan, serta invensi dan inovasi, penyelenggaraan keantariksaan, sedangkan BRIDA merupakan penyelenggara penelitian, pengembangan, pengkajian dan penerapan, serta invensi dan inovasi yang terintegrasi di daerah

2.2 Struktur Organisasi Badan Riset dan Inovasi Nasional

Berdasarkan Peraturan Badan Riset dan Inovasi Nasional Nomor 1 Tahun 2021, berikut merupakan struktur organisasi di lingkungan BRIN.

Gambar 2.1 Struktur Organisasi BRIN

Berdasarkan Pusat Pengembangan Kompetensi BRIN (2021), tugas dan fungsi dari para pelaksana di lingkungan BRIN antara lain:

1. Kepala BRIN
    a. Memimpin dan bertanggung jawab atas pelaksanaan tugas dan fungsi BRIN.
    b. Dalam melaksanakan tugas dan fungsi BRIN, kepala memperhatikan arahan dari dewan pengawas.
    c. Kepala merupakan pengguna anggaran / pengguna barang.
2. Wakil Kepala BRIN
    a. Membantu kepala dalam perumusan kebijakan dan atau pelaksanaan kebijakan BRIN.
    b. Membantu kepala dalam mengkoordinasikan pencapaian kebijakan strategis lintas unit organisasi jabatan pimpinan tinggi madya dan Organisasi Riset (OR) di lingkungan BRIN.
3. Sekretariat Utama
    a. Pengintegrasian sistem penyusunan perencanaan, program,

kelembagaan, dan sumber daya penelitian, pengembangan, pengkajian, penerapan, serta invensi dan inovasi, penyelenggaraan ketenaganukliran dan penyelenggaraan keantariksaan.

b. Pembinaan dan pemberian dukungan administrasi, ketatausahaan, sumber daya manusia, keuangan kerumahtanggaan, arsip dan dokumentasi BRIN.
c. Pengelolaan hubungan masyarakat, keprotokolan, dan pengamanan.
d. Pelaksanaan kerjasama dalam rangka optimalisasi tugas dan fungsi BRIN.
e. Pembinaan dan penataan organisasi dan tata laksana.
f. Pelaksanaan reformasi birokrasi di lingkungan BRIN.
g. Pelaksanaan dan pengoordinasian penyusunan produk hukum dan advokasi hukum.
h. Penyelenggaraan pengelolaan barang milik/kekayaan negara dan pengelolaan pengadaan barang/jasa.
i. Manajemen aparatur sipil negara BRIN.

4. Inspektorat Utama

   Bertugas menyelenggarakan pengawasan intern di lingkungan BRIN.

5. Deputi Bidang Kebijakan Pembangunan

   Bertugas menyelenggarakan pelaksanaan penelitian, pengembangan, pengkajian, penerapan, serta invensi dan inovasi dalam rangka penyusunan rekomendasi kebijakan arah dan prinsip rancangan perencanaan pembangunan nasional dengan berpedoman pada nilai Pancasila.

6. Deputi Bidang Kebijakan Riset dan Inovasi

   Bertugas menyelenggarakan perumusan dan penetapan kebijakan di bidang riset dan inovasi meliputi rencana induk memajukan ilmu pengetahuan dan teknologi, serta peta jalan penelitian, pengembangan, pengkajian, penerapan, serta invensi dan inovasi penyelenggaraan ketenaganukliran dan penyelenggaraan keantariksaan dengan berpedoman pada nilai Pancasila.

7. Deputi Bidang Sumber Daya Manusia Ilmu Pengetahuan dan Teknologi

Memiliki tugas menyelenggarakan perumusan dan pelaksanaan kebijakan di bidang pembinaan, pengembangan kompetensi, pengembangan profesi, manajemen talenta, serta pengawasan dan pengendalian sumber daya manusia ilmu pengetahuan teknologi.

8. Deputi Bidang Infrastruktur Riset dan Inovasi

   Bertugas menyelenggarakan perumusan dan pelaksanaan kebijakan di bidang infrastruktur riset dan inovasi.

9. Deputi Bidang Fasilitasi Riset dan Inovasi

   Memiliki tugas menyelenggarakan perumusan dan pelaksanaan kebijakan di bidang fasilitasi riset dan inovasi.

10. Deputi Bidang Pemanfaatan Riset dan Inovasi

    Bertugas menyelenggarakan perumusan dan pelaksanaan kebijakan di bidang pemanfaatan riset dan inovasi.

11. Deputi Bidang Riset dan Inovasi Daerah

    Bertugas menyelenggarakan koordinasi dan pengendalian penelitian, pengembangan, pengkajian, serta invensi dan inovasi BRIDA.

12. Pusat Pelayanan Teknologi

    Bertugas melaksanakan manajemen pemasaran, manajemen proyek, manajemen kontrak dan lisensi, serta manajemen keuangan dan tata usaha Pusat Pelayanan teknologi.

13. Pusat Data dan Informasi

    Melaksanakan penyiapan penyusunan kebijakan teknis, pelaksanaan, pemanfaatan, evaluasi, dan pelaporan di bidang data.

2.3 Visi dan Misi Tujuan dan Sasaran Strategis Badan Riset dan Inovasi Nasional

Badan Riset dan Inovasi Nasional menetapkan visi yaitu “Badan Riset dan Inovasi Nasional yang andal, professional, inovatif dan berintegritas dalam pelayanan kepada Presiden dan Wakil Presiden untuk mewujudkan Visi dan Misi Presiden dan Wakil Presiden : Indonesia Maju yang Berdaulat, Mandiri, dan Berkepribadian berlandaskan Gotong Royong”

Sebagai upaya untuk mewujudkan visi tersebut di atas, misi Badan Riset dan Inovasi Nasional adalah:

a. Peningkatan Kualitas Manusia Indonesia,
b. Peningkatan Struktur Ekonomi yang Produktif, Mandiri, dan Berdaya Saing,
c. Pembangunan yang Merata dan Berkeadilan,
d. Mencapai Lingkungan Hidup yang Berkelanjutan,
e. Kemajuan Budaya yang Mencerminkan Kepribadian Bangsa, dan
f. Pengelolaan Pemerintahan yang Bersih, Efektif, dan Terpercaya.

Uraian misi tersebut adalah sebagai berikut:

1. Peningkatan Kapabilitas IPTEK, Budaya Riset, dan Penciptaan Inovasi melalui peningkatan Kualitas SDM IPTEK, Penguatan Transformasi Ekonomi, dan Pembangunan Berkelanjutan berlandaskan Budaya Iptek untuk Peningkatan Daya Saing.
2. Peningkatan Pengelolaan Pemerintahan yang Bersih, Efektif, dan Terpercaya.

Misi ini mencakup upaya menjawab permasalahan pembangunan iptek dan pada periode 2020-2024 dalam aspek kebijakan riset dan inovasi, kerja sama pembangunan dan kemitraan, peningkatan penelitian, pengembangan, pengkajian dan penerapan Iptek pada beberapa fokus prioritas riset dan inovasi nasional, serta peningkatan tata kelola pemerintahan yang baik dalam rangka reformasi birokrasi

2.4 Profil Satuan Kerja Tempat Pelaksanaan MBKM

Pusat Riset Sains Data dan Informasi berada di bawah Organisasi Riset Elektronika dan Informatika (OREI) yang dipimpin oleh Dr. Esa Prakasa M.T. Terdapat enam Pusat Riset (PR) di bawah OREI antara lain: PR Telekomunikasi, PR Elektronika, PR Sains Data dan Informasi, PR Kecerdasan Artifisial dan Keamanan Siber, PR Komputasi, dan PR Mekatronika Cerdas.

Berdasarkan Peraturan BRIN No. 10 Tahun 2022 Organisasi Riset Elektronika dan Informatika bertugas menyelenggarakan tugas teknis penelitian, pengembangan, pengkajian, dan penerapan, serta invensi dan inovasi di bidang

elektronika dan informatika sesuai dengan ketentuan peraturan perundang-undangan.

Gambar 2.2 Profil Pusat Riset Sains Data dan Informasi (Organisasi Riset Elektronika dan Informatika)

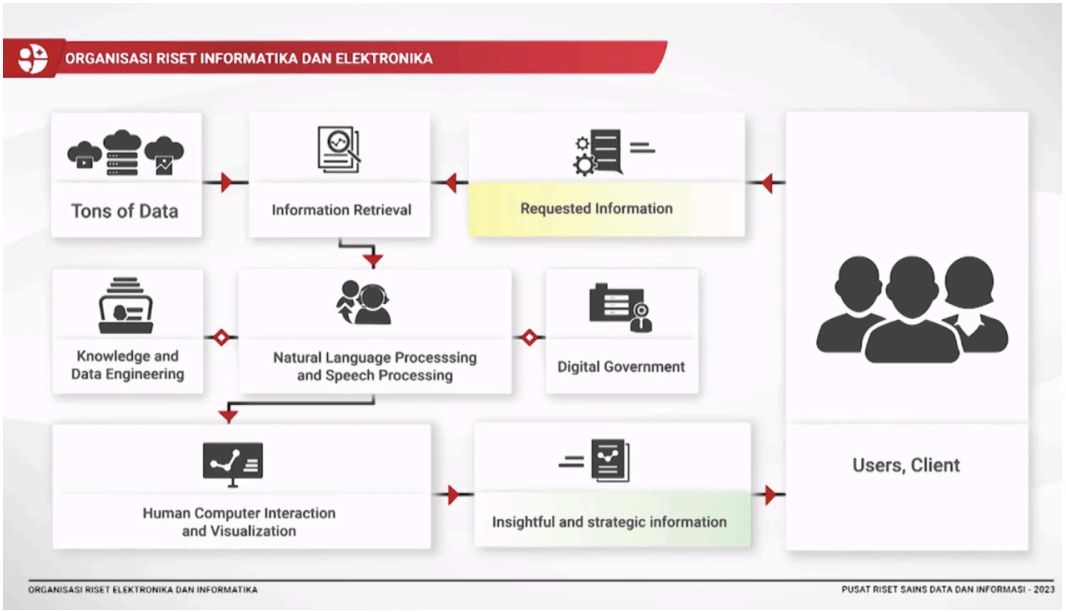

Gambar 2.3 Alur Kerja Pusat Riset Sains Data dan Informasi

Secara khusus, Unit Kerja Pusat Riset Sains Data dan Informasi (PRSDI) yang mempunyai tugas melaksanakan tugas teknis penelitian, pengembangan, pengkajian, dan penerapan, serta invensi dan inovasi di bidang sains data dan

informasi sesuai dengan Pasal 14. PRSDI mendukung tugas dan fungsi pusat riset dengan melaksanakan hal-hal berikut berikut:

1. Pelaksanaan tugas teknis penelitian, pengembangan, pengkajian, dan penerapan, serta invensi dan inovasi di bidang sains data dan informasi.
2. Penyiapan bahan rekomendasi ilmiah atau tanggapan ilmiah di bidang sains data dan informasi.
3. Pemberian bimbingan teknis dan supervisi di bidang sains data dan informasi.
4. Pelaksanaan kerja sama di bidang sains data dan informasi.
5. Pemantauan, evaluasi, dan pelaporan di bidang sains data dan informas

2.5 Profil Kelompok Penelitian/Fungsi Kerja Tempat Pelaksanaan MBKM

Gambar 2.4 Profil Kelompok Riset Information Retrieval (Pusat Riset Sains Data dan Informasi)

Kelompok riset Pengambilan Informasi (*Information Retrieval*) merupakan salah satu kelompok penelitian di Pusat Riset Sains Data dan Informasi. Kelompok penelitian ini diketuai oleh Dr. Purnomo Husnul Khotimah, M.T.

dengan tiga belas anggota, yaitu Dr. Wiwin Suwarningsih, Dr. Anne Parlina, Dr. Lia Sadita, Dr. Ira Maryati, Ir. Dianadewi Riswantini, M. Sc., Ekasari Nugraheni, M.T., Andria Arisal, M. Eng., Andri Fachrur Rozie, M. Eng., Devi Munandar, M.Si., Afnidar Fakhrurrozi, M.Sc., Irfan Asfy Fakhry Anto, M.T., Andre Sihombing, M.Sc., dan Muh. Hafizh Izzaturrahim, S.Kom. Adapun ruang lingkup penelitian adalah sebagai berikut:

1. *Data mining (text extraction, entity recognition, web extraction)*
2. *Data processing (natural language processing, topic/event detection, text/pattern tagging, data integration)*
3. *Data analytics (network graph analysis, natural language analysis, market analysis, medical report analysis)*
4. *Data visualization (information visualization)*

Tentang IRRG (*Information Retrieval Research Group*): Ledakan internet, media sosial, dan teknologi berbasis awan telah mendorong pengembangan model sistem informasi baru dan menciptakan sumber informasi yang sangat besar yang dapat bermanfaat untuk memberikan solusi terhadap permasalahan kemanusiaan dan lingkungan yang muncul. IRRG berperan penting dalam menyediakan kerangka kerja untuk memahami dan mengatasi tantangan informasi ini. Proses menemukan, mengambil, dan mengorganisir informasi yang relevan dari sumber informasi baru ini adalah fokus utama penelitian dan kegiatan IRRG. Ini melibatkan identifikasi data yang diperlukan, pencarian untuk mendapatkannya, dan kemudian mengekstrak serta mengorganisir nya sehingga menjadi bermanfaat, berarti, dan dapat diambil tindakan bagi para pemangku kepentingan. Dengan demikian, IRRG berperan sebagai garda terdepan dalam mengembangkan solusi informatif yang dapat membantu dalam peningkatan kualitas kehidupan manusia dan menjaga keberlanjutan lingkungan.

BAB III

PELAKSANAAN KEGIATAN MBKM

3.1 Uraian Umum Kegiatan MBKM yang Dilakukan

Melalui program MBKM Riset/Penelitian dari Direktorat Manajemen Talenta Badan Riset dan Inovasi Nasional (BRIN), penulis mendapatkan kesempatan untuk melakukan aplikasi ilmu pengetahuan dan teknologi melalui kegiatan riset, pengembangan, serta pengkajian. Kegiatan ini berlangsung pada tanggal 18 Februari 2026 hingga 17 Juli 2026. Skema pelaksanaan terbagi menjadi dua tahapan, yaitu pada minggu pertama dilakukan pembekalan melalui pelatihan pengantar dan pada minggu selanjutnya dilakukan kegiatan pembimbingan penelitian.

Setelah pembekalan awal selesai, penulis memulai riset aktifnya di unit kerja penempatan bersama pembimbing, terletak pada KST Samaun Samadikun Kota Bandung. Penulis difasilitasi dengan peralatan kerja yang memadai dan akan mendapatkan penilaian serta sertifikat sebagai bukti penyelesaian program MBKM. Penulis juga memiliki kewajiban untuk menaati peraturan secara administratif yaitu pengisian kehadiran dan logbook. Penulis juga diharuskan menjaga integritas serta tanggung jawab selama program berlangsung, termasuk dalam hal memelihara Barang Milik Negara (BMN) dan mematuhi kedisiplinan lingkungan kerja BRIN.

3.2 Keterlibatan Penelitian/Riset atau Magang/Praktik Kerja yang Dilakukan

Kegiatan penelitian atau riset yang penulis lakukan meliputi beberapa proses seperti *preprocessing, embedding, undersampling modelling, training,* dan *evaluation*, seperti yang terdapat dalam **Gambar 3.2.1**.

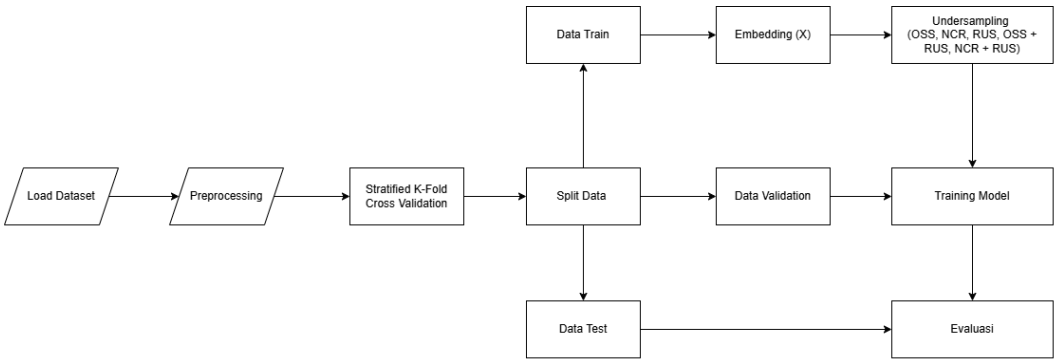

Gambar 3.1 Keterlibatan Riset/Penelitian yang Dilakukan

3.2.1 Data Epidemi

Dalam penelitian ini digunakan data Epidemi sebagai data latih dan data uji. Epidemi merupakan data judul berita online bahasa Indonesia tentang wabah penyakit di Indonesia, antara lain Covid-19, pneumonia, HIV/AIDS, dan lain sebagainya. Data ini berasal dari tiga portal berita Indonesia yaitu Antara, CNN-Indonesia, dan Detik. Data ini mencakup berita pada tahun 2020 hingga 2024. Dengan contoh berita seperti pada **Gambar 3.2.2.1.**

Pelabelan dilakukan pada data yang telah terkumpul. Pelabelan ini berdasar pada sentimen judul berita yang terbagi menjadi tiga kelas yaitu sentimen positif (2), sentimen netral (1), dan sentimen negatif (0). Sentimen positif merupakan informasi terkait wabah yang berisi kejadian positif atau harapan yang menunjukkan situasi membaik, sentimen netral yaitu informasi terkait wabah yang tidak menunjukkan adanya indikasi kejadian positif atau negatif, dan sentimen negatif merupakan informasi terkait wabah yang melaporkan kejadian negatif yang berpotensi memperparah keadaan seperti pada **Tabel 3.1.**

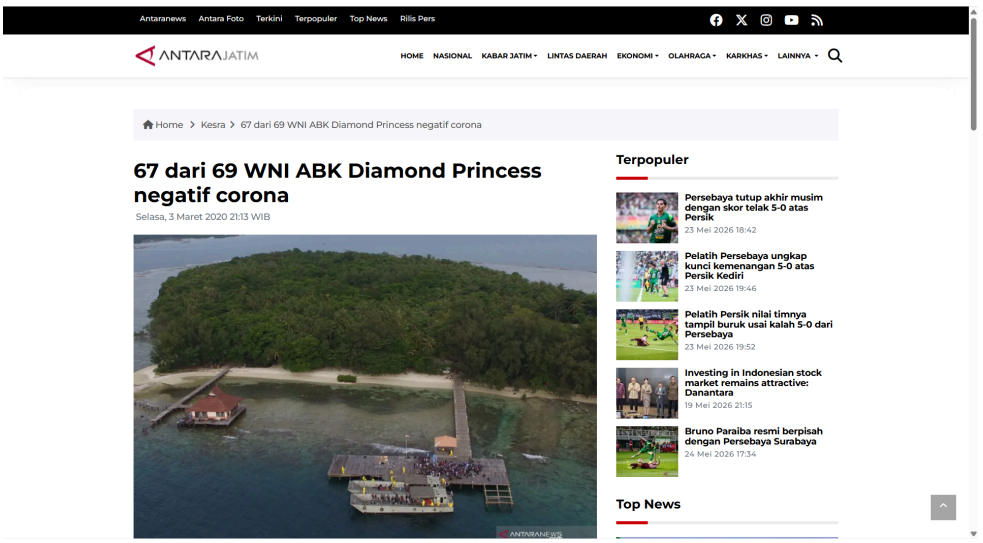

Gambar 3.2 Berita online mengenai covid-19

Tabel 3.1 Sampel klasifikasi data Epidemi

Title	Sentimen
Kemkes: 67 dari 69 WNI ABK Diamond Princess negatif COVID-19	2
Omicron terdeteksi, NTB klaim situasi COVID-19 masih terkendali	1
Satu pasien positif COVID-19 di Kota Kediri meninggal	0

3.2.2 Data *Preprocessing*

Tahapan *preprocessing* teks merupakan proses yang penting dilakukan untuk mengelola data teks yang tidak terstruktur agar menjadi teks yang lebih bersih, konsisten, dan siap digunakan untuk proses analisis selanjutnya. Tahapan preprocessing yang dilakukan yang pertama yaitu penghapusan data duplikat. Data berita yang berulang dalam dataset akan dihapus untuk memastikan keunikan informasi serta menghindari bias pada tahapan analisis berikutnya.

Setelah dataset bersih dari duplikasi, dilanjutkan dengan pelabelan secara manual *(manual labeling)* yang melibatkan sepuluh mahasiswa sebagai annotator. Seluruh annotator dibagi secara merata ke dalam dua tim yang masing-masing beranggotakan lima mahasiswa. Dataset dengan total awal sebanyak 48.179 data dikelompokkan menjadi dua bagian pengerjaan, yakni event_project1 dan

event_project2. Setelah dilakukan labeling *event* dan *non-event* dilanjutkan pelabelan sentimen pada data yang dideteksi sebagai event yaitu sebanyak 17.444 data. Lalu dibagi menjadi dua bagian yakni, sentiment_project1 dan sentiment_project2, pelabelan menggunakan tiga kategori sentimen, yaitu negatif, netral, dan positif. Penulis mengukur tingkat konsistensi antar-annotator, dilakukan uji reliabilitas menggunakan metode *Fleiss' Kappa*. Fleiss' Kappa merupakan metode untuk mengukur tingkat konsistensi pelabelan dua lebih annotator (Numiqo, n.d). Pada sentimen_project1 diperoleh nilai *Percent Agreement* (PA) sebesar 98,05% dan *Expected Agreement* (PE) sebesar 76,59%, sehingga menghasilkan skor *Fleiss' Kappa* sebesar 91,66%. Adapun pada sentimen_project2 nilai PA sebesar 89,20% dan PE sebesar 69,12% menghasilkan skor *Fleiss' Kappa* sebesar 65,03%. Dari kedua proyek tersebut dapat dilihat bahwa proyek pertama memiliki homogenitas yang lebih tinggi dibanding dengan proyek kedua.

Tahapan selanjutnya adalah pembersihan data *(cleaning data)*, yaitu menghilangkan komponen teks yang tidak relevan seperti simbol-simbol khusus, spasi yang berlebih, serta karakter asing yang terbawa selama proses scraping dari portal berita. Terakhir, dilakukan *case folding,* yakni proses pengubahan seluruh karakter huruf dalam teks menjadi huruf kecil *(lowercase)* agar format kata seragam, terstandarisasi, dan lebih mudah diproses secara komputasi.

3.2.3 Stratified K-Fold

Tahapan *Stratified K-Fold* merupakan parameter yang diberi label ‘k’ untuk menentukan jumlah lipatan dataset pada pembagian *k-fold*. Dalam metode ini, setiap data memiliki lipatan dalam dataset dengan peluang (k-1) kali dalam set pelatihan. Pada penelitian ini menggunakan nilai k=5 (n_splits=5), sehingga dataset dibagi menjadi lima subset dengan distribusi kelas yang relatif sama. Setiap iterasi, satu lipatan digunakan sebagai data uji atau data *testing*, sedangkan empat lipatan lainnya digunakan sebagai data latih atau data *training*. Data latih tersebut akan dibagi lagi menggunakan train_test_split menjadi 95% data latih dan

5% data validasi dengan parameter stratify, sehingga proporsi setiap kelas tetap sama pada data latih dan data validasi.

3.2.4 Representasi Vektor (*Embedding*)

Setelah tahap *preprocessing* selesai, data yang telah bersih tidak dapat langsung diproses oleh algoritma selanjutnya, karena algoritma selanjutnya membutuhkan masukan data berupa angka bukan kalimat atau kata. Sehingga dilakukan tahapan *embedding* terlebih dahulu untuk mentransformasikan setiap kata atau token di dalam teks ke dalam bentuk vektor numerik berdimensi tinggi. Proses ini berfungsi untuk memetakan karakteristik semantik, hubungan sintak, dan konteks antar-kata ke dalam ruang vektor kontinu. Melalui representasi vektor ini, informasi teks dari judul berita dapat disajikan secara matematis sehingga siap untuk diolah pada tahapan selanjutnya.

Metode embedding yang digunakan pada penelitian ini adalah Sentence Embedding berbasis Sentence-BERT (SBERT) dengan model all-MiniLM-L6-v2. SBERT merupakan pengembangan dari arsitektur BERT yang dirancang untuk menghasilkan representasi semantik pada tingkat kalimat dengan mempertahankan konteks secara lebih baik (Reimers dan Gurevych, 2019). Model all-MiniLM-L6-v2 dipilih karena dapat menghasilkan representasi vektor berdimensi 384 dengan efisiensi komputasi yang tinggi. Menurut Wang et al (2020), MiniLM dikembangkan dengan menggunakan teknik Deep Self-Attention Distillation yang memungkinkan model mempertahankan performa teknik BERT-Base meskipun memiliki jumlah parameter yang lebih kecil. Model memiliki keuntungan yaitu proses ekstraksi fitur yang lebih efisien tanpa mengurangi kualitas representasi teks secara signifikan.

3.2.5 Penanganan Ketidakseimbangan Data (*Undersampling*)

Ketidakseimbangan kelas *(imbalance data)* merupakan ketimpangan jumlah data yang signifikan antara kategori sentimen negatif, netral, dan positif. Metode penanganan ketidakseimbangan data pada tingkat data umumnya dibagi menjadi pendekatan utama, yaitu *oversampling* dan *undersampling* (Kaur et al., 2019). *Oversampling* adalah teknik menyeimbangkan kelas dengan

memperbanyak jumlah sampel pada kelas minoritas, baik melalui duplikasi data atau pembuatan data sintetis baru (Kaur et al., 2019). Sedangkan, *undersampling* merupakan sebuah teknik yang menyeimbang dataset dengan cara membuang atau mengurangi sebagian sampel dari kelas mayoritas (Kaur et al., 2019). Penulis menggunakan metode *undersampling* dibanding *oversampling* karena untuk menjaga integritas semantik teks. Pada pemrosesan bahasa alami, manipulasi kata untuk menciptakan teks sintetis baru (*text generation* atau data *augmentation*) sangat berisiko merusak struktur konteks kalimat dan mengubah validitas makna aslinya (Bayer et al., 2021). Dataset dalam penelitian ini berupa berita mengenai penyakit menular yang membutuhkan akurasi informasi yang tinggi, sehingga metode *undersampling* lebih aman dibandingkan dengan *oversampling*.

Penulis menerapkan tiga metode undersampling untuk mengatasi ketidakseimbangan kelas, yaitu RUS (Random Sampling), OSS (One-Sided Selection), NCR (Neighbourhood Cleaning Rule). RUS merupakan komputasi yang bekerja dengan cara memilih dan menghapus sampel dari kelas mayoritas secara acak hingga distribusinya seimbang dengan kelas minoritas atau dapat ditulis secara eksplisit (Machine Learning Mastery).

Metode yang pendekatannya lebih selektif yaitu *One-Sided Selection* (OSS) yang diterapkan untuk menangani ketidakseimbangan data dengan cara mengeliminasi sampel dari kelas mayoritas yang bersifat redundan atau *noise* secara selektif (Laurikkala, 2001; Bennehalli et al., 2024; Patil & Shekokar, 2025). OSS menyederhanakan batas antar-kelas dengan mengkombinasikan aturan dari *Condensed Nearest Neighbour* (CNN) dan *Tomek Links* (Laurikkala, 2001). CNN diterapkan untuk menemukan subset data yang konsisten dengan cara mempertahankan seluruh sampel minoritas dan menyimpan ke dalam sampel kelas mayoritas yang salah diklasifikasikan, sehingga data yang mudah diklasifikasikan dibuang karena dianggap redundan (Laurikkala, 2001). Selanjutnya, *Tomek Links* digunakan untuk mengidentifikasi dan menghapus sisa data kelas mayoritas yang ada di area perbatasan (Laurikkala, 2001).

Selain metode OSS terdapat metode *Neighborhood Cleaning Rule* (NCR). NCR merupakan sebuah metode yang digunakan untuk menangani

ketidakseimbanga data dengan cara mengurangi jumlah dari kelas mayoritas dan mempertahankan kelas minoritas (Chauhan dan Gandotra, 2025). Secara teknis NCR ini menggunakan algoritma *Edited Nearest Neighbours* (ENN) yang digunakan untuk menghilangkan noise atau data yang membingungkan di batas antar-kelas. ENN bekerja dengan mengevaluasi k tetangga terdekat dari suatu titik data, jika mayoritas label tetangga berbeda maka data tersebut akan dianggap noise.

3.2.6 Modelling

Setelah tahapan penyeimbangan data, langkah berikutnya adalah mengintegrasikan data ke dalam arsitektur model *deep learning* yang telah dipersiapkan. Proses penyiapan data dimulai dengan memuat komponen Tokenisasi IndoBERT untuk memecah teks menjadi token-token yang dapat dikenali oleh model bahasa, dilanjutkan dengan instansiasi class dataset, serta pembuatan dataloader untuk mengatur ukuran batch selama proses berlangsung. Data yang telah siap kemudian dilanjutkan ke dalam arsitektur model, yaitu model hibrida IndoBERT-CNN-BiLSTM. Metode IndoBERT (*Indonesian Bidirectional Encoder Representations from Transformers*) merupakan model bahasa *pretrained* monolingual yang dikembangkan secara khusus menggunakan korpus Indo4B yang mencakup lebih dari 220 juta kata dari berbagai sumber yang menggunakan *WordPiece vocabulary* berukuran 31.923 kosa kata dan berjalan selama 2,4 juta *steps* watau 180 epoch (Koto et al., 2020; Imaduddin et al., 2023). Keunggulan IndoBERT yaitu memiliki kemampuan menangkap konteks bahasa dengan dua mekanisme yaitu *Masked Language Modeling* (MLM) untuk melakukan prediksi kata yang disembunyikan dalam kalimat, dan *Next Sentence Prediction* (NSP) untuk memahami hubungan logis antarkalimat (Geni et al., 2023; Widiyatama et al., 2025).

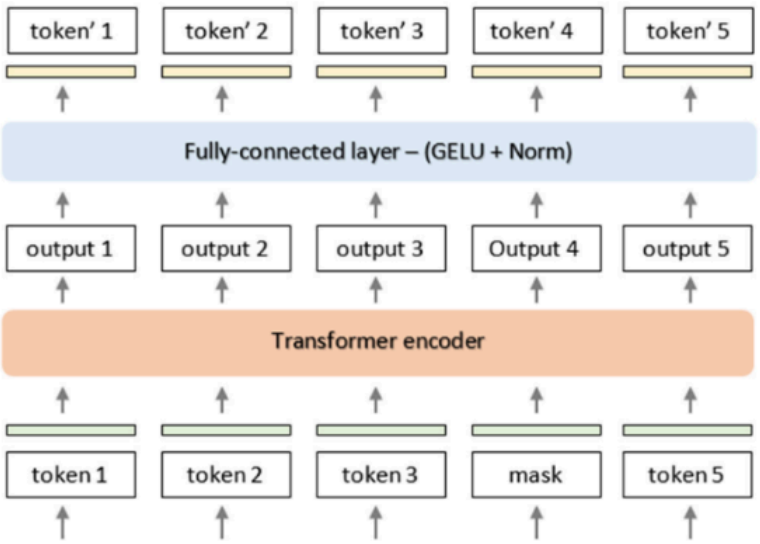

Gambar 3.3 Arsitektur IndoBERT

Sumber: Miranda et al., 2023

Metode kedua adalah CNN (*Convolutional Neural Network*) merupakan salah satu arsitektur deep learning yang tersusun atas tiga komponen yaitu, *convolutional layer*, *pooling layer*, dan *fully connected layer* (Lu et al., 2021). Lapisan konvolusi bertugas untuk mengekstraksi fitur lokal dari data inputan (Lu et al., 2021). Setelah proses konvolusi menghasilkan representasi fitur dengan dimensi yang tinggi, pooling layer ditambahkan untuk reduksi dimensi. Salah satu metode *pooling* yang digunakan adalah *max pooling* yang bekerja dengan mengambil nilai maksimum dari suatu area tertentu pada feature map (Shan et al., 2021). Lapisan terakhir adalah *fully connected* yang berfungsi untuk mempelajari kombinasi non-linear dari fitur-fitur yang telah diekstraksi oleh lapisan konvolusi dan kemudian akan digunakan untuk menghasilkan keluaran akhir (Shrivastava et al., 2023).

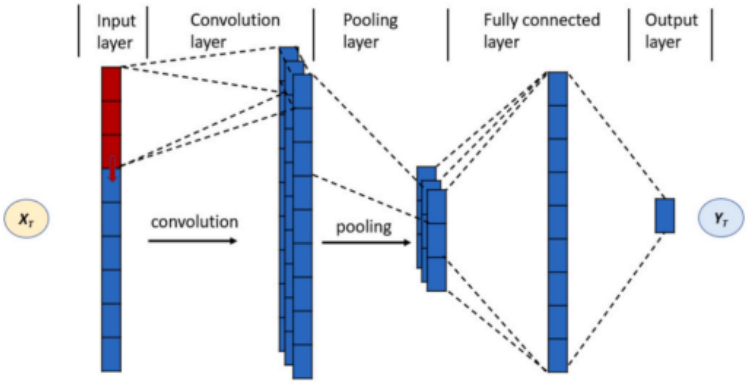

Gambar 3.4 Arsitektur CNN 1-D

Sumber: Shan et al., 2021

Metode terakhir yaitu metode BiLSTM (*Bidirectional Long Short-Term Memory*). BiLSTM merupakan metode yang menggabungkan dua lapisan LSTM yang bekerja secara paralel, yaitu forward atau memproses urutan data dari awal ke akhir dan backward atau memproses urutan data dari akhir ke awal (Shan et al., 2021). Arsitektur dua arah ini membuktikan bahwa BiLSTM adalah metode unggul dibandingkan dengan RNN dan LSTM konvensional dalam berbagai tugas yang membutuhkan pemahaman konteks yang lebih kaya, karena mampu memanfaatkan informasi masa lalu dan masa depan dari suatu urutan data (Shrivastava et al., 2023; Shan et al., 2021).

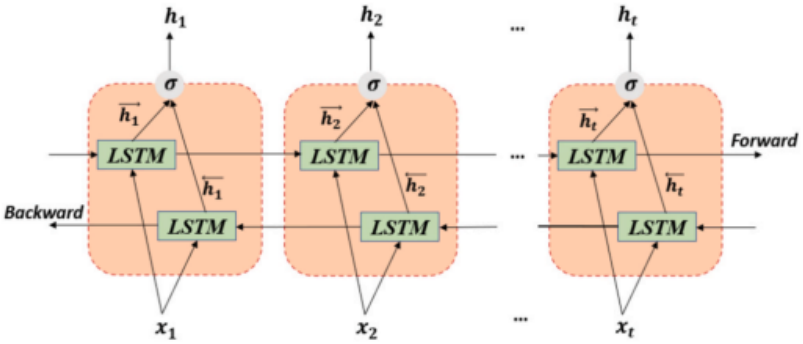

Gambar 3.5 Arsitektur BiLSTM

Sumber: Shan et al., 2021

3.2.7 Evaluation Matrix

Performa dan efektivitas model hibrida IndoBERT-CNN-BiLSTM perlu

dilakukan pengukuran dengan menggunakan beberapa metrik evaluasi yang berbasis pada *Confusion Matrix*. Berdasarkan metodologi Grandini et al. (2020), metrik yang digunakan meliputi *Accuracy, Precision, Recall,* dan *F1-Score*. Keempat metrik ini dihitung menggunakan kombinasi nilai True Positive (TP), True Negative (TN), False Positive (FP), dan False Negative (FN).

3.2.7.1 Accuracy

Menurut Grandini et al. (2020) *accuracy* merupakan metrik yang mengukur proporsi jumlah prediksi yang benar terhadap keseluruhan data pengujian. Semakin tinggi nilai accuracy, semakin besar jumlah data yang berhasil diprediksi dengan benar.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

3.2.7.2 Precision

Menurut Grandini et al. (2020) *precision* digunakan untuk mengukur tingkat ketepatan model dalam melakukan prediksi suatu kelas tertentu. Nilai precision yang tinggi menunjukkan bahwa model memiliki tingkat kesalahan false positive yang rendah.

$$Precision = \frac{TP}{TP + FP}$$

3.2.7.3 Recall

Menurut Grandini et al. (2020) *recall* digunakan untuk mengukur kemampuan model dalam mengidentifikasi seluruh data yang benar-benar termasuk dalam suatu kelas tertentu. Semakin tinggi nilai recall, semakin rendah tingkat false negative yang dihasilkan model.

$$Recall = \frac{TP}{TP + FN}$$

3.2.7.4 F1-Score

Menurut Grandini et al. (2020) *F1-Score* merupakan rata-rata antara *precision* dan *recall* yang digunakan untuk menyeimbangkan kedua metrik tersebut. *F1-Score* dapat digunakan pada kasus klasifikasi dengan distribusi kelas yang tidak seimbang karena mampu memberikan evaluasi yang lebih stabil dibandingkan hanya menggunakan accuracy.

$$F1\text{-}Score = 2\ (\frac{precision\ .\ recall}{precision + recall})$$

3.2.7.5 AUC-ROC

Menurut Tafvizi et al. (2022), AUC-ROC (*Area Under Curve – Receiver Operating Characteristic)* digunakan untuk mengukur kemampuan model dalam membedakan antar kelas berdasarkan probabilitas prediksi yang dihasilkan.

Tabel 3.2 Perbandingan Hasil Evaluasi Metrik

Metode	Accuracy	Precision	Recall	F1-Score
IndoBERT-CNN-BiLTM	**86.29%**	**80.47%**	80.36%	**80.41%**
IndoBERT-CNN-BiLTM + NCR	84.82%	78.59%	**81.21%**	79.61%
IndoBERT-CNN-BiLTM+ OSS	84.49%	78.36%	80.95%	79.37%
IndoBERT-CNN-BiLTM+ RUS (2.300 data)	82.21%	75.71%	80.63%	77.43%
IndoBERT-CNN-BiLTM+ OSS + RUS (2.300 Data)	81.64%	75.43%	80.79%	77.14%
IndoBERT-CNN-BiLTM+ NCR + RUS (2.300 Data)	81.15%	75.17%	81.17%	76.96%

Tabel 3.3 Hasil AUC-ROC

Metode	AUC-ROC
IndoBERT-CNN-BiLTM	90.79%
IndoBERT-CNN-BiLTM + NCR	**91.62%**
IndoBERT-CNN-BiLTM + OSS	91.37%
IndoBERT-CNN-BiLTM + RUS (2.300 Data)	90.98%
IndoBERT-CNN-BiLTM + OSS + RUS (2.300 Data)	89.91%

IndoBERT-CNN-BiLTM + NCR + RUS (2.300 Data)	90.23%

Model IndoBERT-CNN-BiLTM menghasilkan nilai *accuracy* tertinggi sebesar 86.29% dan unggul dalam nilai F1-Score yaitu 80.41%. Hal ini menunjukkan bahwa penambahan metode *undersampling* seperti NCR, OSS, dan RUS dapat menurunkan kinerja model yang mengindikasikan kehilangan informasi penting akibat pengurangan data. Dengan demikian, penggunaan *undersampling* pada kasus ini tidak efektif, dan model IndoBERT-CNN-BiLTM sudah optimal tanpa teknik penyeimbangan data tambahan.

3.3 Penugasan-Penugasan yang Telah Diselesaikan

Penugasan yang diberikan selama kegiatan MBKM meliputi kegiatan pembelajaran dasar, *review* jurnal ilmiah, pengolahan data, pengembangan model, mengikuti pertemuan pekanan, serta melakukan presentasi progres mingguan. Pada tahap awal, penulis mengikuti proses orientasi dan pengenalan lingkungan riset di Pusat Riset Sains Data dan Informasi BRIN, termasuk paparan terkait ruang lingkup penelitian, mekanisme kerja, serta topik riset yang akan dilakukan. Selain itu, penulis juga melakukan *set up tools* yang diperlukan untuk mendukung kegiatan penelitian serta mempelajari dasar-dasar *deep learning* sebagai landasan utama penelitian.

Sertifikat

No. 203/STMP/PM/2/2026

Menyatakan bahwa

Aulia Kartika Putri

telah mengikuti

Pelatihan Pembekalan Magang BRIN
Semester Genap 2025/2026

Pelatihan diselenggarakan pada tanggal 09 s.d 13 Februari 2026 oleh Direktorat Pengembangan Kompetensi Badan Riset dan Inovasi Nasional, selama 25 jam pelatihan.

Jakarta, 16 Februari 2026
Badan Riset dan Inovasi Nasional
Direktorat Pengembangan Kompetensi
Plt Direktur,

TT ELEKTRONIK

Rahma Lina, M.E.

Gambar 3.6 Sertifikat Pelatihan Pengantar MBKM BRIN

No. 203/STMP/PM/2/2026

Materi Pelatihan Pembekalan Magang BRIN
Semester Ganjil 2025/2026

No.	Materi Pelatihan	Jam
1	*Overview* Pelatihan	3
2	*Building Learning Commitment*	3
3	Mengenal Badan Riset dan Inovasi Nasional	3
4	Pengantar *Research Integrity*	3
5	Jurnal Ilmiah & Manajemen Referensi	3
6	Tim Efektif	3
7	Teknik Presentasi	4
8	Evaluasi Akademik	3
	Jumlah Total	**25**

Jakarta, 16 Februari 2026
Ketua Tim Fungsi Layanan Learning Management System (LMS)
Pengembangan Kompetensi SDM

TT ELEKTRONIK

Indra Riswadinata, M.H.

Gambar 3.7 Daftar Mata Pelatihan Pengantar MBKM BRIN

Setelah tahap orientasi, penulis mulai mendalami berbagai materi terkait *Machine Learning*, seperti *preprocessing* teks, teknik klasifikasi, serta algoritma

machine learning dan *deep learning*, diantaranya *Support Vector Machine* (SVM), *Naive Bayes*, *Random Forest*, *Logistic Regression*, hingga model *Deep Learning* seperti CNN, LSTM, dan BiLSTM. Pembelajaran ini dilakukan melalui berbagai sumber seperti jurnal ilmiah, artikel, dan referensi penelitian sebelumnya yang relevan dengan topik yang diangkat.

Penulis diberikan tugas untuk melakukan *review* terhadap beberapa jurnal penelitian yang berkaitan dengan analisis sentimen dan klasifikasi teks. Beberapa jurnal yang dipelajari antara lain berjudul "CNN-Based Hybrid Performance Evaluation Towards Online News Sentiment Classification Task", yang membahas penggunaan model hybrid CNN, LSTM, dan BiLSTM untuk meningkatkan performa klasifikasi sentimen, serta jurnal "Sentiment Analysis Methods, Applications, and Challenges: A Systematic Literature Review" yang memberikan pemahaman menyeluruh terkait metode, aplikasi, dan tantangan dalam analisis sentimen. Selain itu, penulis juga mempelajari teknik penanganan data *imbalance* menggunakan metode *undersampling.*

Setelah memahami konsep dasar dan referensi penelitian, penulis mulai mengimplementasikan proses pengolahan data yang meliputi *preprocessing* teks seperti penghapusan duplikat data, labeling data secara manual, *cleaning*, *case folding,* dan t*okenization*. Selanjutnya, penulis mengembangkan model klasifikasi dengan pendekatan menggunakan IndoBERT, CNN, dan BiLSTM. Dalam proses ini, penulis juga melakukan menerapkan metode *undersampling* untuk menghasilkan model terbaik serta melakukan perbaikan kode secara bertahap untuk mengatasi error yang muncul selama proses implementasi. Tahap selanjutnya adalah evaluasi model, penulis mengukur performa model menggunakan berbagai metrik evaluasi seperti *accuracy*, *precision*, *recall*, *F1-score*, dan AUC-ROC. Evaluasi ini dilakukan untuk mengetahui seberapa baik model dalam melakukan klasifikasi sentimen terhadap data judul berita online. Hasil evaluasi ini kemudian dianalisis untuk menentukan model terbaik berdasarkan performa yang dihasilkan.

Selain kegiatan teknis, penulis juga secara rutin mengikuti pertemuan pekanan bersama tim riset dan pembimbing. Dalam pertemuan ini, penulis

mempresentasikan progres penelitian, mendiskusikan kendala yang dihadapi, serta mendapatkan arahan dan masukan untuk pengembangan penelitian selanjutnya. Kegiatan ini memberikan kesempatan bagi penulis untuk meningkatkan kemampuan komunikasi, berpikir kritis, serta memperluas wawasan di bidang sains data dan kecerdasan buatan. Selain itu penulis juga mengikuti kegiatan webinar yang diselenggarakan oleh BRIN. Webinar ini membahas mengenai penelitian yang sedang di *development*. Secara keseluruhan, seluruh penugasan yang telah dilaksanakan memberikan pengalaman praktis bagi penulis dalam menerapkan teori yang telah dipelajari ke dalam konteks penelitian nyata, khususnya dalam bidang analisis sentimen berbasis *deep learning* dan pengolahan data teks.

3.4 Pembelajaran Hal Baru (*Lessons Learned*) yang Diperoleh

Berdasarkan pengalaman dalam menjalani program ini, terdapat beberapa pembelajaran baru yang saya peroleh:

a. Pentingnya Ketelitian dalam Pelabelan Data

   Penulis memahami bahwa proses pelabelan data merupakan tahapan yang sangat penting dalam penelitian analisis sentimen dan klasifikasi data. Ketelitian dalam menentukan label sangat berpengaruh terhadap kualitas dataset dan hasil model yang dibangun. Dari proses ini, penulis belajar untuk lebih konsisten, objektif, dan memahami konteks data sebelum menentukan suatu label.

b. Pemahaman mengenai Proses *Preprocessing* Data

   Penulis memperoleh pengalaman baru mengenai tahapan *preprocessing* data teks, seperti *cleaning* data, tokenisasi, *case folding*. Tahapan ini membantu penulis memahami bahwa kualitas data yang baik akan sangat mempengaruhi performa model *deep learning* yang digunakan.

c. Mengenal Teknis Analisis Sentimen dan *Machine Learning*

   Selama proses pembelajaran, penulis mulai memahami bagaimana teknik analisis sentimen bekerja, mulai dari pengumpulan data hingga proses klasifikasi. Penulis juga mempelajari beberapa algoritma dan metode baru

seperti IndoBERT dan BiLSTM yang digunakan untuk melakukan analisis terhadap data teks. Hal ini memberikan wawasan baru mengenai penerapan kecerdasan buatan dalam pengolahan bahasa alami (*Natural Language Processing*).

d. Pentingnya Kolaborasi dan Diskusi

   Selama kegiatan berlangsung, penulis mendapatkan banyak pengalaman melalui diskusi dan arahan dari dosen pembimbing maupun rekan tim. Kolaborasi tersebut membantu penulis memahami materi yang sebelumnya sulit dipahami serta memberikan sudut pandang baru dalam menyelesaikan permasalahan penelitian.

e. Pengembangan Kemampuan Berpikir Analitis

   Melalui proses penelitian dan analisis data, penulis menjadi lebih terbiasa berpikir secara sistematis dan analitis dalam menyelesaikan suatu permasalahan. Penulis belajar bagaimana membaca pola data, mengevaluasi hasil model, serta menarik kesimpulan berdasarkan data yang diperoleh.

f. Manajemen Waktu dan Konsistensi

   Penulis menyadari bahwa penelitian membutuhkan konsistensi dan manajemen waktu yang baik. Pembagian waktu antara belajar teori, implementasi, dan evaluasi menjadi hal penting agar progres penelitian tetap berjalan dengan optimal.

BAB IV

PENUTUP

4.1 Kesimpulan

Program MBKM Riset/Penelitian di Badan Riset dan Inovasi Nasional berlangsung selama 6 bulan dari 18 Februari 2026 hingga 31 Juli 2026. Kegiatan MBKM Riset yang telah dilaksanakan di Pusat Riset Sains Data dan Informasi BRIN, dapat disimpulkan bahwa seluruh rangkaian kegiatan, mulai dari pembelajaran dasar, pengolahan data, pengembangan model, hingga evaluasi, telah memberikan pengalaman dalam bidang data science, khususnya analisis sentimen berbasis *Natural Language Processing* (NLP). Penelitian ini berhasil mengimplementasikan model IndoBERT-CNN-BiLSTM untuk melakukan klasifikasi sentimen pada data judul berita epidemi berbahasa Indonesia. Hasil penelitian menunjukkan bahwa penggunaan pendekatan IndoBERT-CNN-BiLTM tanpa penambahan metode *undersampling* mampu meningkatkan performa model dibandingkan metode yang menggunakan penambahan metode *undersampling*. Sehingga penerapan teknik penanganan data *imbalance* seperti *One-Sided Selection* (OSS), *Neighbourhood Cleaning Rule* (NCR), dan *Random Undersampling* (RUS) terbukti tidak berpengaruh terhadap peningkatan performa model.

Hasil evaluasi menunjukkan bahwa model IndoBERT-CNN-BiLTM tanpa penggunaan metode *undersampling* menghasilkan nilai akurasi tertinggi sebesar 86.29% serta nilai F1-Score sebesar 80.41%, yang menunjukkan performa terbaik dalam menghasilkan prediksi yang benar secara keseluruhan. Dengan demikian, penggunaan *undersampling* pada kasus ini tidak efektif, dan model IndoBERT-CNN-BiLTM sudah optimal tanpa teknik penyeimbangan data tambahan.

Secara keseluruhan, kegiatan MBKM ini berhasil mencapai tujuan penelitian, yaitu menganalisis pengaruh metode undersampling dalam mengatasi class imbalance, membandingkan performa model IndoBERT-CNN-BiLTM

dengan dan tanpa undersampling. Selain capaian teknis, kegiatan ini juga memberikan peningkatan kemampuan dalam berpikir analitis, pemecahan masalah, dan komunikasi ilmiah yang relevan dengan dunia riset dan industri.

4.2 Saran

Untuk memastikan optimalisasi pelaksanaan program MBKM di masa mendatang, disarankan untuk menyusun silabus atau rencana penelitian yang mencakup seluruh durasi program. Silabus ini perlu merinci tahapan pelaksanaan, materi yang akan diajarkan, serta target pencapaian yang diinginkan. Dengan adanya silabus, setiap peserta program dapat memiliki panduan yang jelas mengenai perjalanan penelitian mereka sehingga dapat menghindari keterlambatan atau kelalaian dalam mencapai target waktu. Rencana penelitian yang terstruktur akan membantu menjaga fokus dan konsistensi dalam setiap langkah, memastikan bahwa progres tidak terlupakan dan selaras dengan tujuan yang telah ditetapkan. Langkah ini tidak hanya meningkatkan akuntabilitas peserta program, tetapi juga memastikan keberlanjutan dan kesuksesan program MBKM Riset/Penelitian di Badan Riset dan Inovasi Nasional. Selain penyusunan silabus, adanya pengelolaan dataset yang lebih terstandarisasi, khususnya dalam proses pelabelan dan validasi data. Hal ini penting guna untuk menjaga kualitas dataset agar penelitian yang diperoleh lebih akurat.

DAFTAR PUSTAKA

Asosiasi Penyelenggara Jasa Internet Indonesia. (2025). Laporan survei penetrasi internet Indonesia 2025. https://gizmologi.id/insight/survei-internet-indonesia-2025/

Badan Riset dan Inovasi Nasional. (2022). Profil Badan Riset dan Inovasi Nasional. https://brin.go.id/page/6/profil

Bayer, M., Kaufhold, M.-A., & Reuter, C. (2021). A survey on data augmentation for text classification. https://arxiv.org/pdf/2107.03158

Bennehalli, S. J., Vakkund, S., Hegde, H. A., & Bhowmik, B. (2024). Navigating data imbalances in credit risk management: A one-sided selection approach. 2024 Control Instrumentation System Conference (CISCON). IEEE.

Chauhan, K., & Gandotra, E. (2025). Hybrid sampling technique for imbalanced Android malware family classification. SN Computer Science, 6, 209.

Geni, L., Yulianti, E., & Sensuse, D. I. (2023). Sentiment analysis of tweets before the 2024 elections in Indonesia using IndoBERT language models. Jurnal Ilmiah Teknik Elektro Komputer dan Informatika (JITEKI), 9(3), 746–757.

Grandini, M., Bagli, E., & Visani, G. (2020). Metrics for multi-class classification: An overview. arXiv preprint arXiv:2008.05756.

Imaduddin, H., A'la, F. Y., & Nugroho, Y. S. (2023). Sentiment analysis in Indonesian healthcare applications using IndoBERT approach. International Journal of Advanced Computer Science and Applications (IJACSA), 14(8), 113–117.

Kaur, H., Pannu, H. S., & Malhi, A. K. (2019). A systematic review on imbalanced data challenges in machine learning: Applications and solutions.

Koto, F., Rahimi, A., Lau, J. H., & Baldwin, T. (2020). IndoLEM and IndoBERT: A benchmark dataset and pre-trained language model for Indonesian NLP. Proceedings of the 28th International Conference on Computational Linguistics (COLING), 757–770.

Liu, B. (2012). Sentiment analysis and opinion mining. Synthesis Lectures on Human Language Technologies, 5(1), 1–167.

Lu, W., Li, J., Wang, J., & Qin, L. (2021). A CNN-BiLSTM-AM method for stock price prediction. Neural Computing and Applications, 33, 4741–4753.

Machine Learning Mastery. (n.d.). Undersampling algorithms for imbalanced classification. https://machinelearningmastery.com/undersampling-algorithms-for-imbala

nced-classification/

Miranda, C. H., Sanchez-Torres, G., & Salcedo, D. (2023). Exploring the evolution of sentiment in Spanish pandemic tweets: A data analysis based on a fine-tuned BERT architecture. Data, 8(6), 96.

Numiqo. (n.d.). Fleiss' kappa tutorial. https://numiqo.com/tutorial/fleiss-kappa

Pang, B., & Lee, L. (2008). Opinion mining and sentiment analysis. Foundations and Trends in Information Retrieval, 2(1–2), 1–135.

Patil, S., & Shekokar, N. (2025). An optimized ADASYN-OSS data balancing approach with wrapper-based feature selection for phishing detection. 2025 IEEE Pune Section International Conference (PuneCon). IEEE.

Shan, L., Liu, Y., Tang, M., Yang, M., & Bai, X. (2021). CNN-BiLSTM hybrid neural networks with attention mechanism for well log prediction. Journal of Petroleum Science and Engineering, 205, 108838.

Shrivastava, P. K., Sharma, M., Sharma, P., & Kumar, A. (2023). HCBiLSTM: A hybrid model for predicting heart disease using CNN and BiLSTM algorithms. Measurement: Sensors, 25, 100657.

Tafvizi, A., Avci, B., & Sundararajan, M. (2022). Attributing AUC-ROC to analyze binary classifier performance. arXiv preprint arXiv:2205.11781.

Widiyatama, O., Rozak, F., Rozie, A. F., Arisal, A., & Kurniasari, D. (2025). BERT-based multi-task classification model for free health check-up program analysis. Proceedings of the 2025 International Conference on Computer, Control, Informatics and its Applications (IC3INA).

LAMPIRAN

Biodata peserta MBKM

Nama : Aulia Kartika Putri
NIM : 235150207111033
Program Studi : Teknik Informatika
Fakultas : Fakultas Ilmu Komputer
Universitas : Universitas Brawijaya

Biodata pembimbing BRIN

Nama : Andri Fachrur Rozie, SKom., M.Eng.
NIP : 198510102008121002
Satuan Kerja : Pusat Riset Sains Data dan Informasi
Jabatan : Penelaah Teknis Kebijakan
Pangkat/Gol : Penata Muda Tingkat I III/b

Biodata pembimbing Universitas

Nama : Yuita Arum Sari, S.Kom., M.Kom., Ph.D.

NIK/NIDN : 2016098807152001/0015078803

Jabatan : Fungsional Dosen /TMT

Mata Kuliah : Visi Komputer Tingkat Lanjut, Sistem Pendukung Keputusan, Matematika Diskrit, Kecerdasan Artifisial Lanjut, Kalkulus.

Dokumentasi

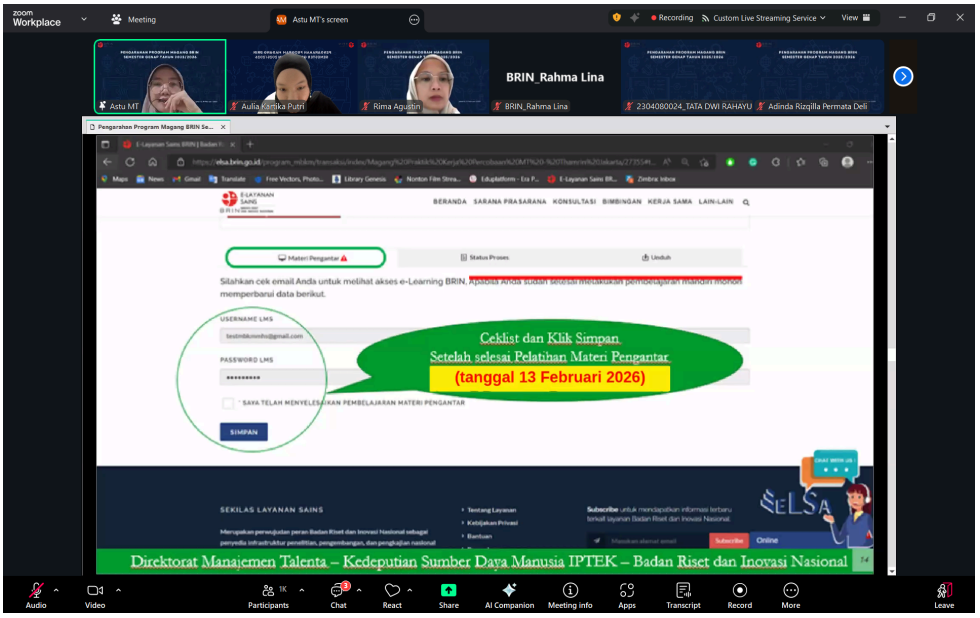

Gambar 5.1 Pertemuan Pengantar MBKM

Gambar 5.2 Perkenalan Mahasiswa Pusat Riset Sains Data dan Informasi

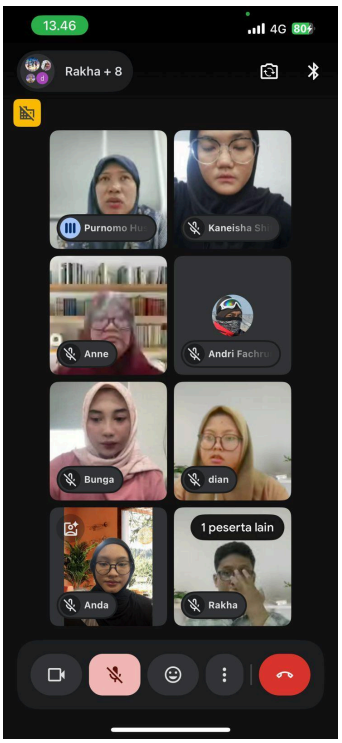

Gambar 5.3 Penjelasan Mengenai Penelitian *Information Retrieval*

Gambar 5.4 Mengikuti Pelatihan *Safety Induction*

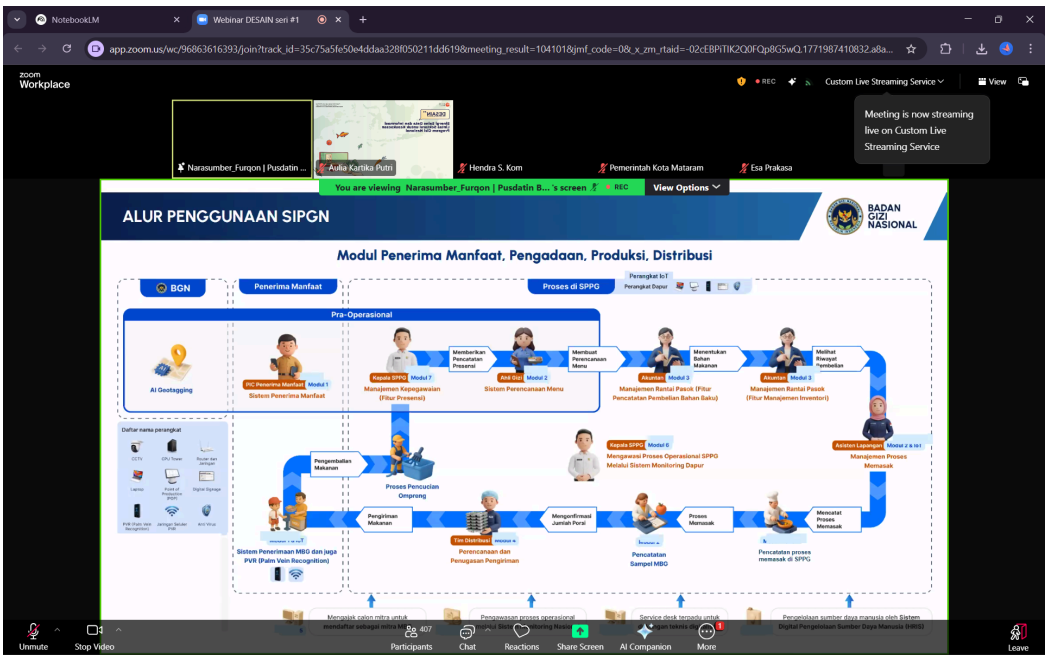

Gambar 5.5 Mengikuti Kegiatan Webinar DESAIN 1

Gambar 5.6 Pertemuan Mingguan dengan Pembimbing

Gambar 5.7 Pertemuan Mingguan dengan Pembimbing

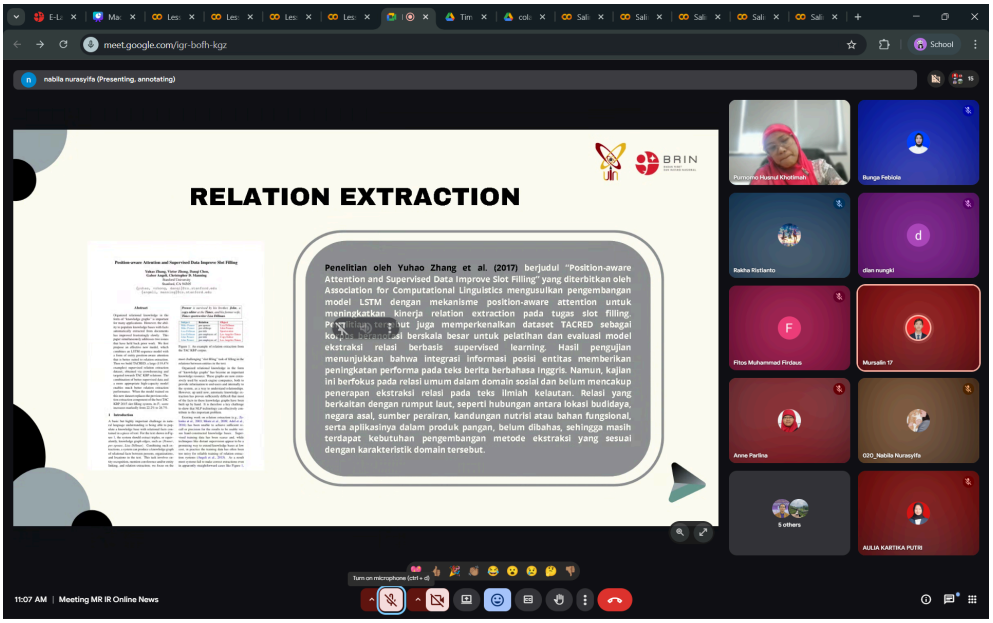

Gambar 5.8 Pertemuan Progress Mingguan dengan Tim Online News

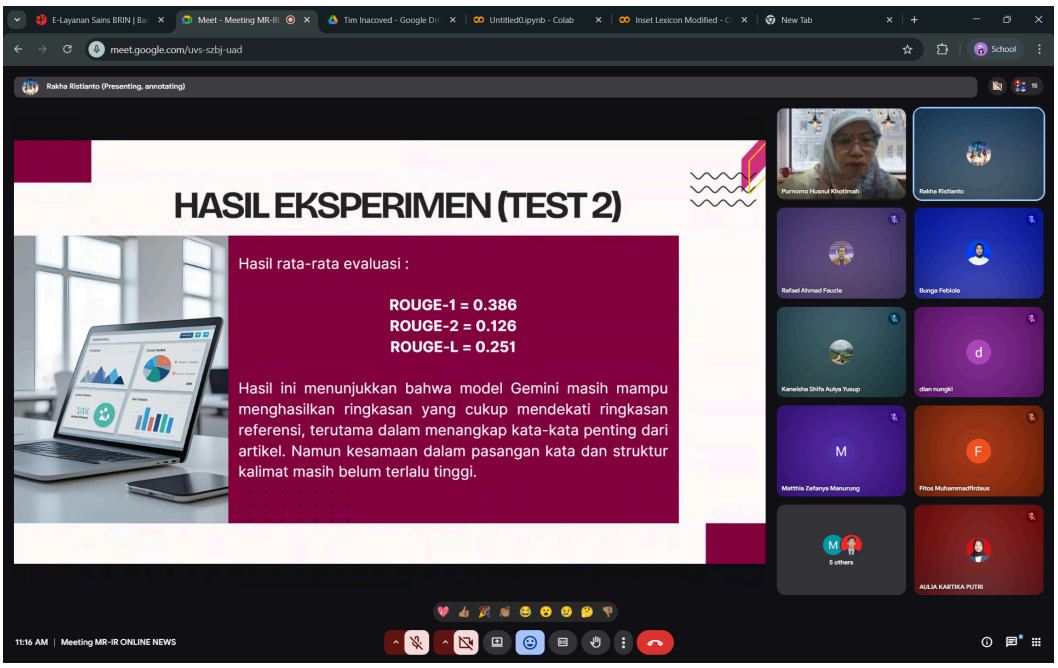

Gambar 5.9 Pertemuan Progress Mingguan dengan Tim Online News

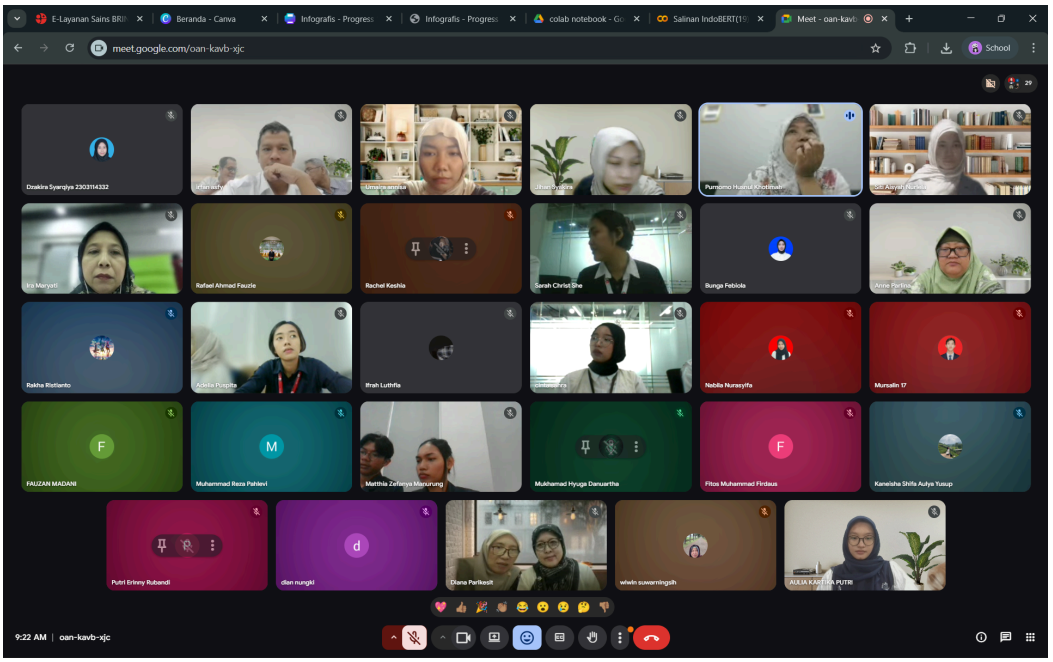

Gambar 5.10 Pertemuan Progress Mingguan dengan Tim Information Retrieval

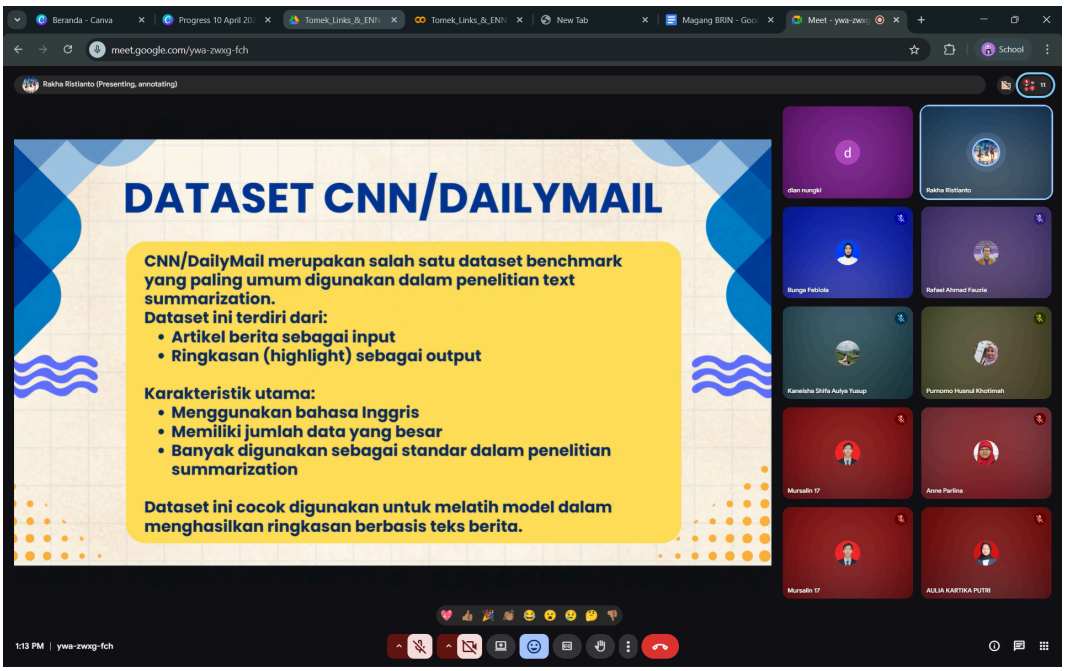

Gambar 5.11 Pertemuan Progress Mingguan dengan Tim Online News

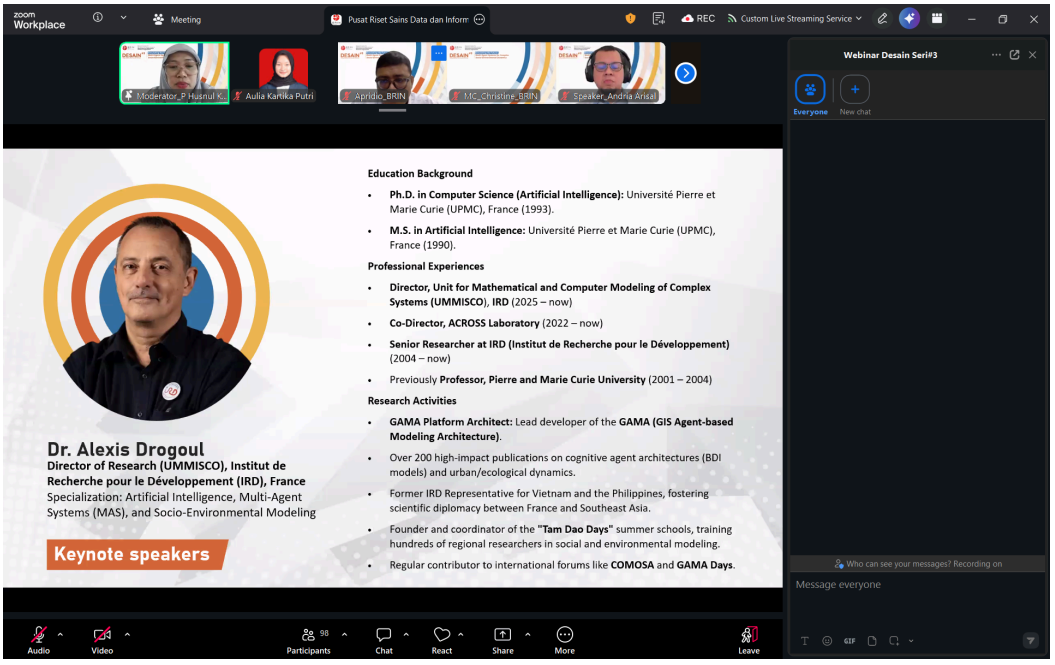

Gambar 5.12 Mengikuti Webinar DESAIN 3.

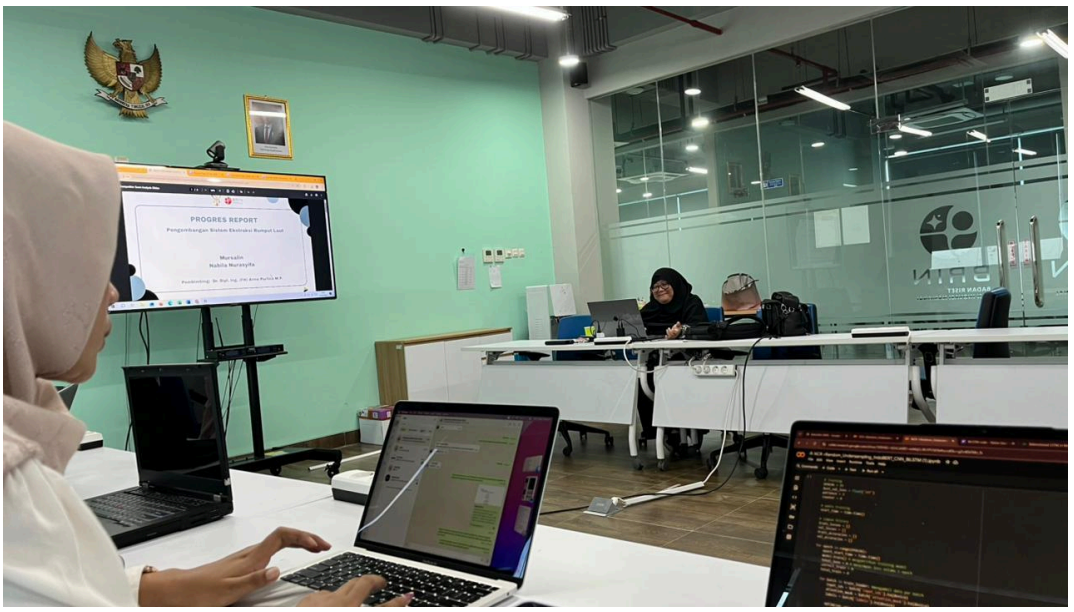

Gambar 5.13 Pertemuan Progress Mingguan dengan Tim Online News

Gambar 5.14 *Class* Tambahan Belajar GIT

Gambar 5.15 Pertemuan Progress Mingguan dengan Tim Online News

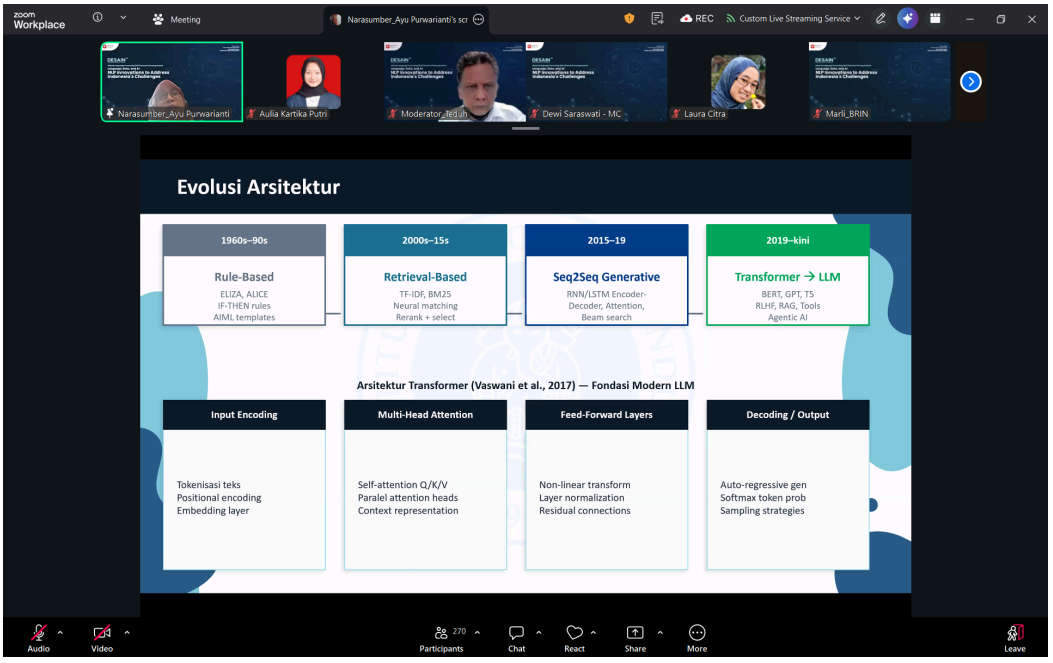

Gambar 5.16 Mengikuti Webinar DESAIN 4

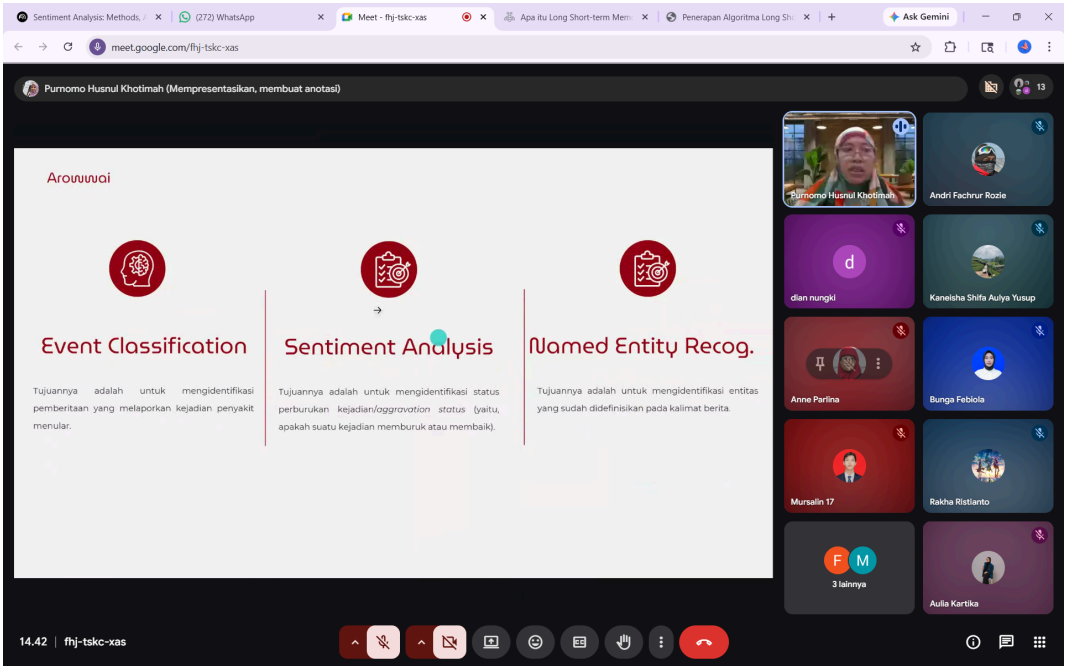

Gambar 5.17 Pertemuan Progress Mingguan dengan Tim Online News

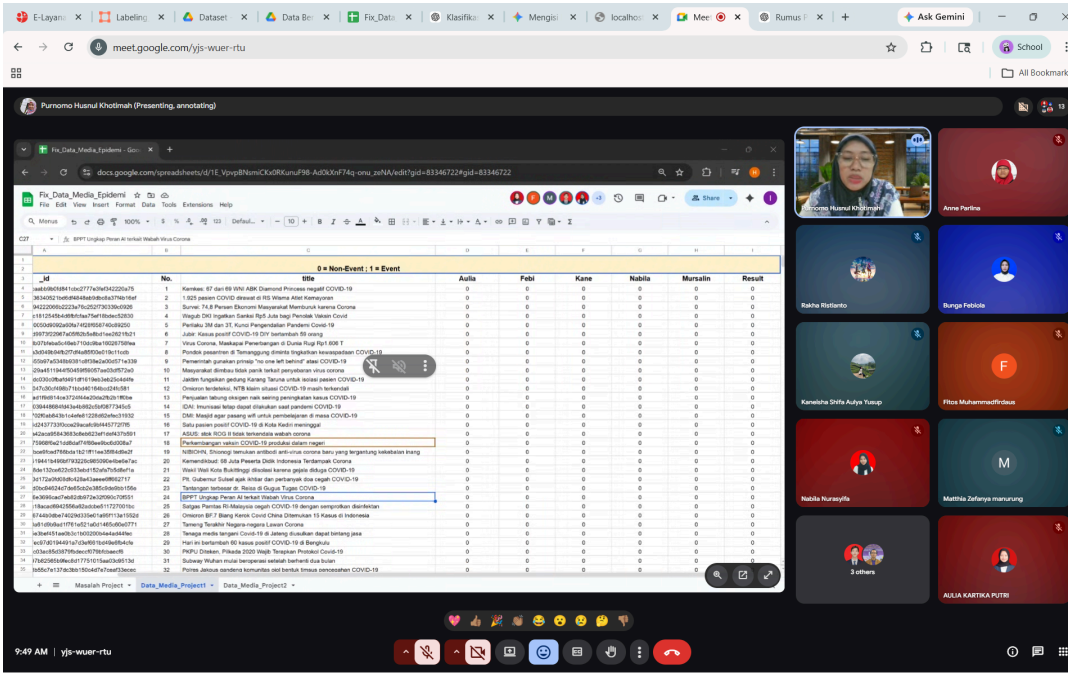

Gambar 5.18 Pertemuan Progress Mingguan dengan Tim Online News

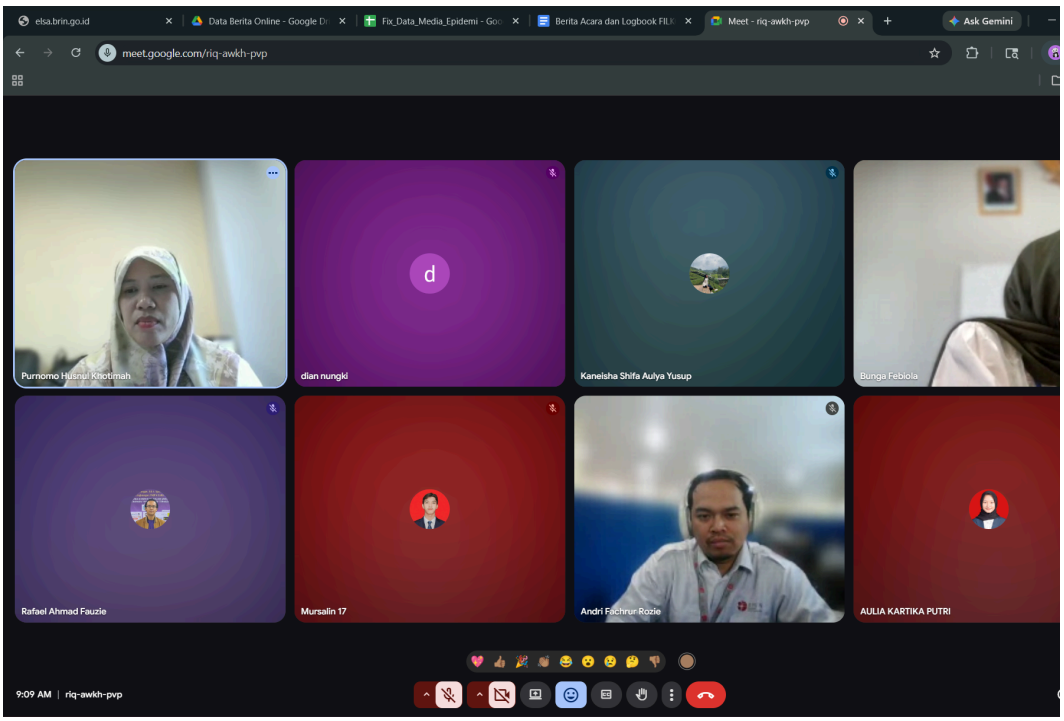

Gambar 5.19 Pertemuan Progress Mingguan dengan Tim Online News

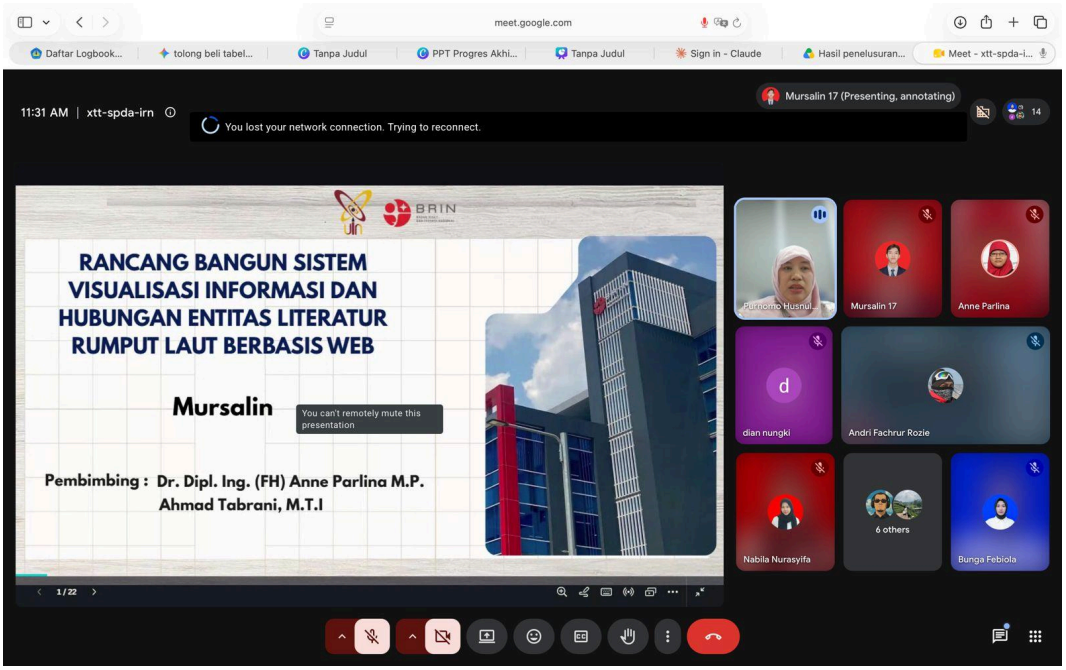

Gambar 5.20 Pertemuan Progress Mingguan

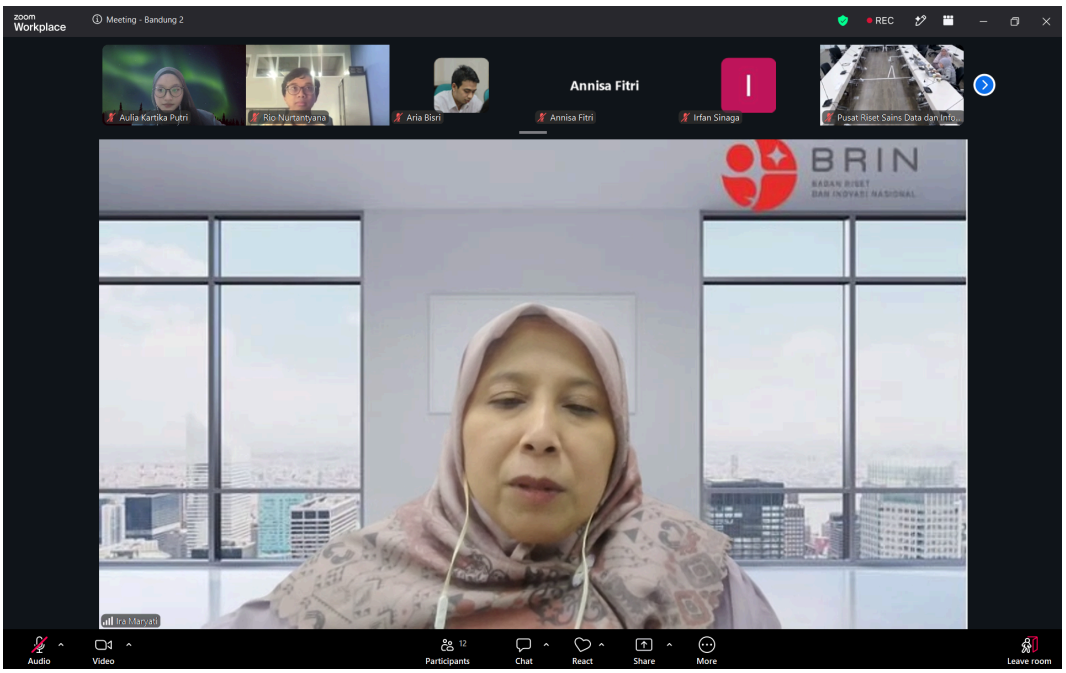

Gambar 5.21 Presentasi Akhir

Luaran Kegiatan MBKM

1. Code : https://drive.google.com/drive/folders/10SicTAiJ4EHIrekf-h8kfERPM1fQ-nmX?usp=sharing
2. Dataset : https://drive.google.com/drive/folders/1UiE392-I7k7h-xw_5ubYUpNCd0I966oF?usp=sharing
3. PPT : https://www.canva.com/design/DAHKqoXs1As/QDCaAl33omxX2paYRTtoOQ/edit