ANALISIS SENTIMEN PEMBERITAAN PENYAKIT MENULAR PADA PORTAL BERITA ONLINE MENGGUNAKAN INDOBERT-CNN-BILSTM

Disusun Oleh :
Aulia Kartika Putri
Universitas Brawijaya

Pembimbing :
Andri Fachrur Rozie, S.Kom., M.Eng
Yuita Arum Sari, S.Kom., M.Kom., Ph.D



LATAR BELAKANG

1. Tingginya penetrasi internet di Indonesia (80,66%) mendorong dominasi berita online sebagai sumber informasi utama.
2. Berita penyakit menular dapat memengaruhi persepsi, psikologis, dan perilaku kesehatan masyarakat.
3. Selain keakuratan informasi, cara penyampaian berita juga memengaruhi persepsi, sehingga perlu analisis sentimen.
4. Mengidentifikasi distribusi sentimen (positif, negatif, netral) sebagai bahan evaluasi penyampaian informasi.
5. Tantangan utamanya kompleksitas bahasa Indonesia dan ketidakseimbangan data.
6. Menggunakan teknik undersampling dan model hybrid IndoBERT-CNN-BiLSTM.

TUJUAN

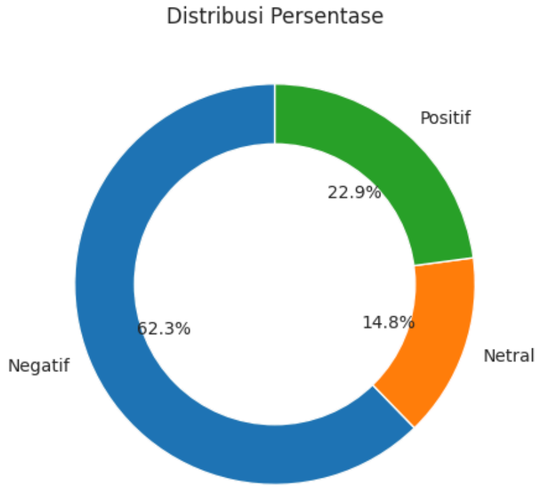
1. Menganalisis pengaruh metode Undersampling dalam mengatasi class imbalance pada dataset berita penyakit menular.

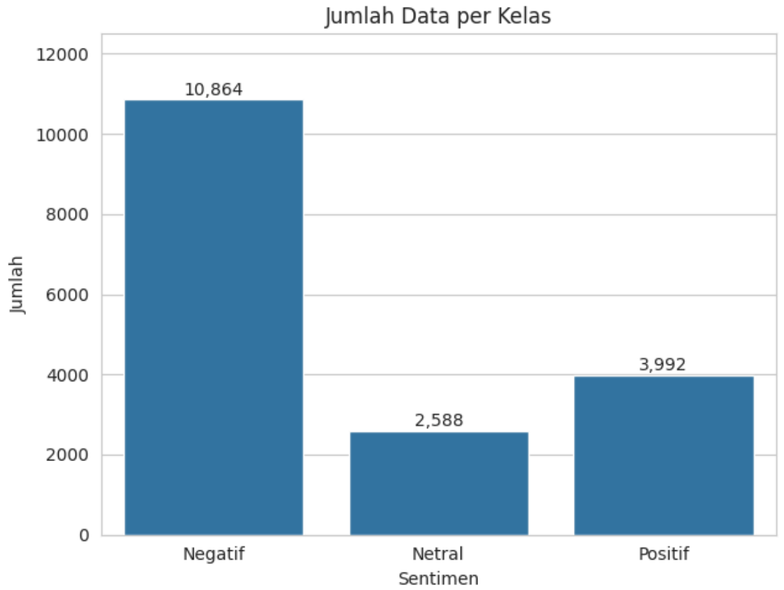
2. Membandingkan performa model hibrida IndoBERT-CNN-BiLSTM dengan dan tanpa penerapan Undersampling dalam klasifikasi sentimen.

DATASET EPIDEMI

	title	Sentiment	title_case_folding	title_cleaned	title_tokenization
0	Kemkes: 67 dari 69 WNI ABK Diamond Princess ne...	2	kemkes: 67 dari 69 wni abk diamond princess ne...	kemkes 67 dari 69 wni abk diamond princess neg...	['kemkes', '67', 'dari', '69', 'wni', 'abk', '...
1	1.925 pasien COVID dirawat di RS Wisma Atlet K...	0	1.925 pasien covid dirawat di rs wisma atlet k...	1925 pasien covid dirawat di rs wisma atlet ke...	['1925', 'pasien', 'covid', 'dirawat', 'di', '...
2	Jubir: Kasus positif COVID-19 DIY bertambah 59...	0	jubir: kasus positif covid-19 diy bertambah 59...	jubir kasus positif covid19 diy bertambah 59 o...	['jubir', 'kasus', 'positif', 'covid19', 'diy'...
3	Jaktim fungsikan gedung Karang Taruna untuk is...	1	jaktim fungsikan gedung karang taruna untuk is...	jaktim fungsikan gedung karang taruna untuk is...	['jaktim', 'fungsikan', 'gedung', 'karang', 't...
4	Omicron terdeteksi, NTB klaim situasi COVID-19...	1	omicron terdeteksi, ntb klaim situasi covid-19...	omicron terdeteksi ntb klaim situasi covid19 m...	['omicron', 'terdeteksi', 'ntb', 'klaim', 'sit...
...	...	...	...	...	...
17439	Penambahan kasus COVID-19 terbanyak di Jakarta...	0	penambahan kasus covid-19 terbanyak di jakarta...	penambahan kasus covid19 terbanyak di jakarta ...	['penambahan', 'kasus', 'covid19', 'terbanyak'...
17440	Klaster Persiapan Hajatan Bantul, 70 orang Pos...	0	klaster persiapan hajatan bantul, 70 orang pos...	klaster persiapan hajatan bantul 70 orang posi...	['klaster', 'persiapan', 'hajatan', 'bantul', ...
17441	Eks Direktur WHO Minta Pemerintah Serius Dalam...	1	eks direktur who minta pemerintah serius dalam...	eks direktur who minta pemerintah serius dalam...	['eks', 'direktur', 'who', 'minta', 'pemerinta...
17442	Pasien positif COVID-19 di RSKD Duren Sawit pe...	0	pasien positif covid-19 di rskd duren sawit pe...	pasien positif covid19 di rskd duren sawit per...	['pasien', 'positif', 'covid19', 'di', 'rskd',...
17443	Kasus positif COVID-19 pada 18 Februari bertam...	0	kasus positif covid-19 pada 18 februari bertam...	kasus positif covid19 pada 18 februari bertamb...	['kasus', 'positif', 'covid19', 'pada', '18', ...

17444 rows × 5 columns





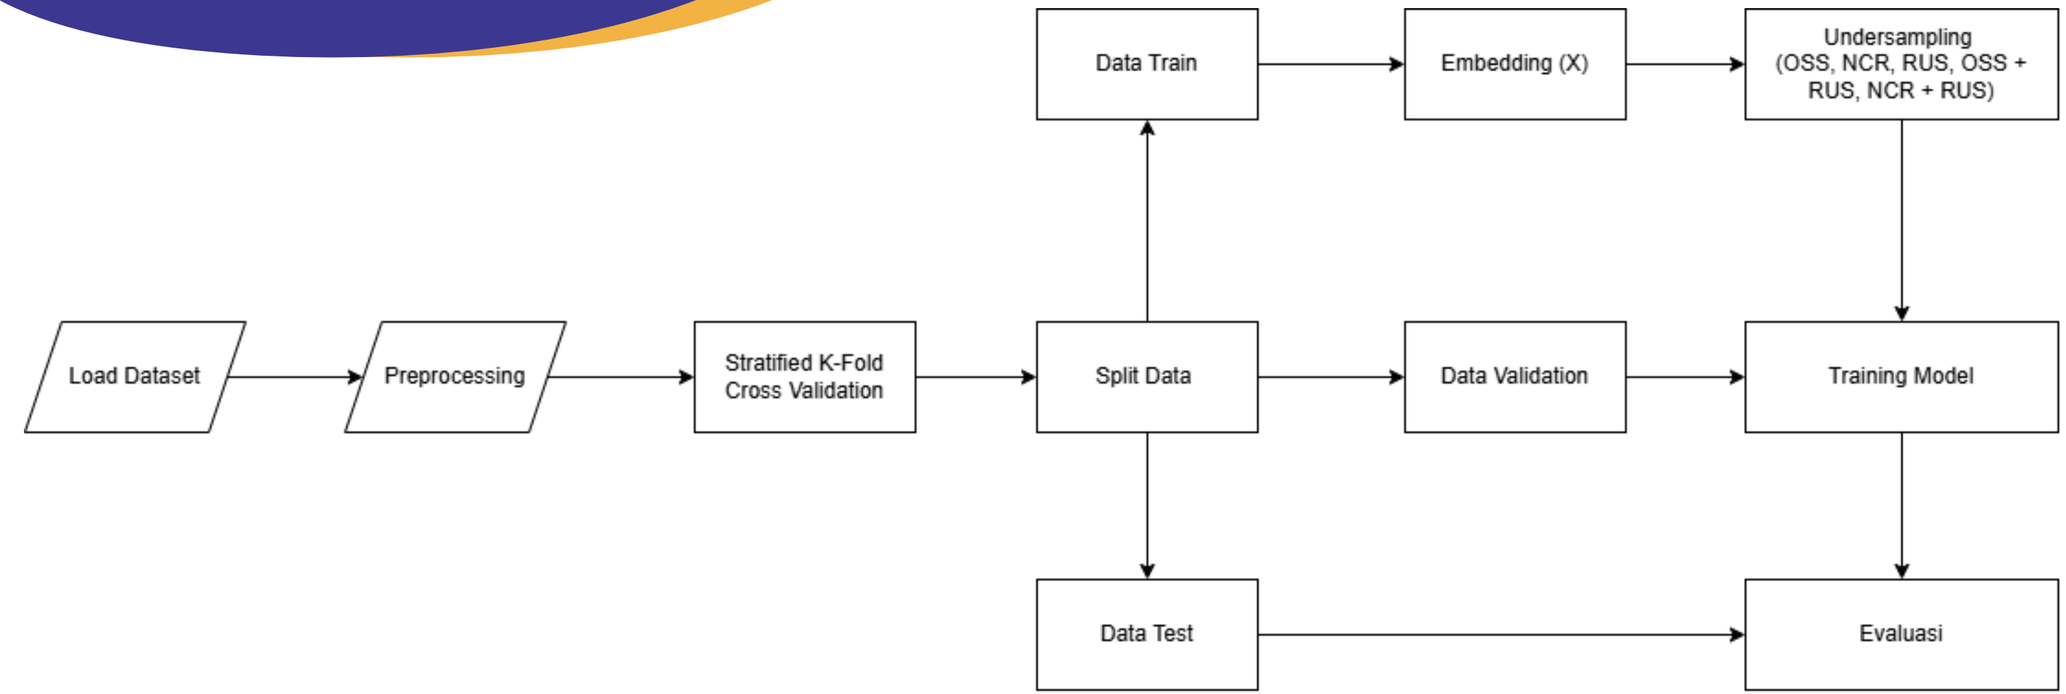
KATEGORI SENTIMENT

Judul	Sentimen
Kemkes: 67 dari 69 WNI ABK Diamond Princess negatif COVID-19	1
Omicron terdeteksi, NTB klaim situasi COVID-19 masih terkendali	0
Satu pasien positif COVID-19 di Kota Kediri meninggal	-1

Note:

- Sentimen positif (1) : informasi terkait wabah yang berisi kejadian positif atau harapan yang menunjukkan situasi membaik.
- Sentimen netral (0) : informasi terkait wabah yang tidak menunjukkan adanya indikasi kejadian positif atau negatif.
- Sentimen negatif (-1) : informasi terkait wabah yang melaporkan kejadian negatif yang berpotensi memperparah keadaan.

METODOLOGI


Load Dataset
Preprocessing
Stratified K-Fold Cross Validation
Split Data
Data Train
Embedding (X)
Undersampling (OSS, NCR, RUS, OSS + RUS, NCR + RUS)
Data Validation
Training Model
Data Test
Evaluasi

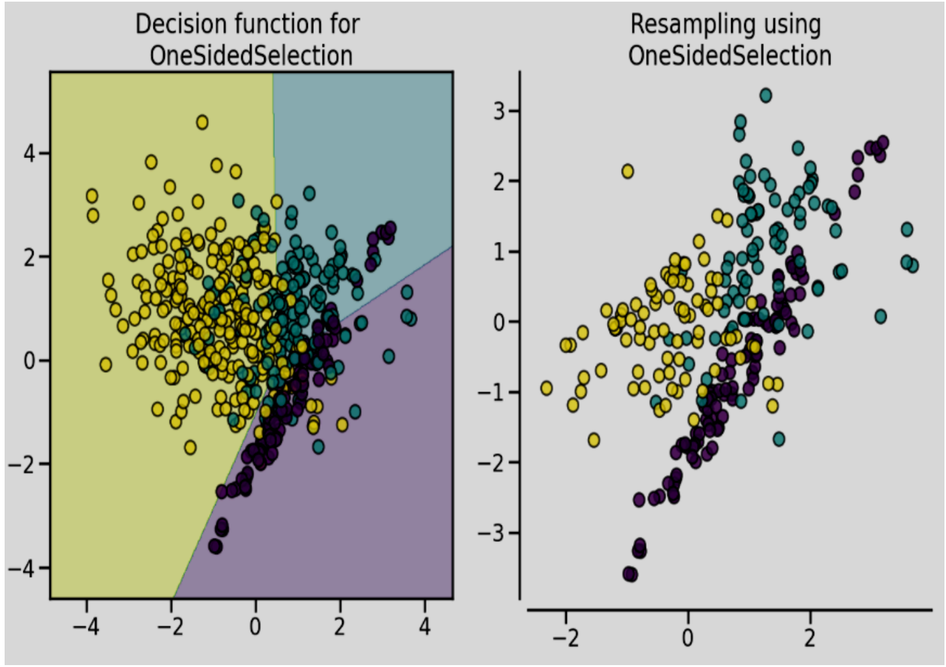
METODE HYBRID

IndoBERT (**Indonesian Bidirectional Encoder Representations from Transformers**)	**CNN** (**Convolutional Neural Network**)	**BiLSTM** (**Bidirectional Long Short-Term Memory**)
IndoBERT adalah model representasi bahasa yang dilatih khusus pada korpus bahasa Indonesia. **IndoBERT menggunakan mekanisme self-attention untuk memahami hubungan antar** kata tanpa mempedulikan jaraknya. Mampu memberikan representasi kontekstual yang lebih akurat.	**CNN** merupakan jenis jaringan saraf tiruan yang terdiri dari **lapisan konvolusi, lapisan pooling, dan lapisan terhubung penuh**. Dalam arsitektur hybrid, CNN digunakan **untuk mereduksi dimensi** dari output IndoBERT dan **mengambil fitur-fitur penting**.	Bidirectional Long Short-Term Memory (BiLSTM) merupakan pengembangan jaringan saraf LSTM. Mekanisme BiLSTM adalah memungkinkan model memproses urutan teks dari arah maju (forward) dan mundur (backward). Mampu memahami konteks dua arah.

METODE UNDERSAMPLING

OSS (One-Sided Selection)

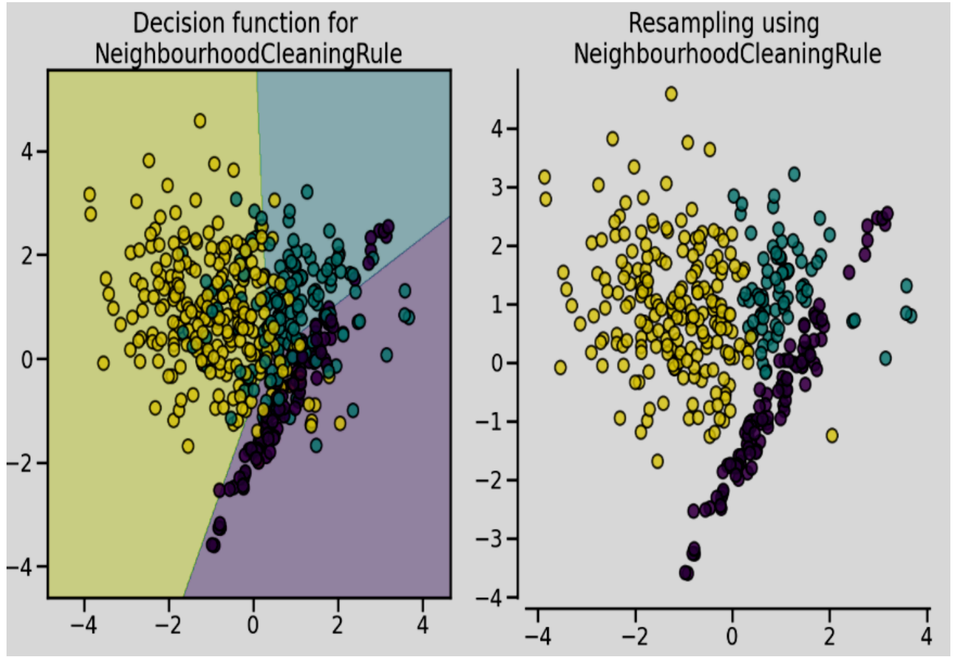
OSS merupakan **metode yang menggabungkan Tomek Links** untuk menghapus data mayoritas yang overlap melalui identifikasi tetangga terdekat antar kelas, dan **CNN** (**Condensed Nearest Neighbor**) yang bekerja dengan menyimpan sebagian kecil data sebagai acuan, lalu menambahkan data lain jika tidak dapat diklasifikasikan dengan benar, sehingga data mayoritas yang tidak penting dapat dihilangkan. OSS akan menghasilkan dataset yang lebih representatif dan memiliki batas antar kelas yang lebih jelas.



METODE UNDERSAMPLING

NCR(Neighborhood Cleaning Rule)

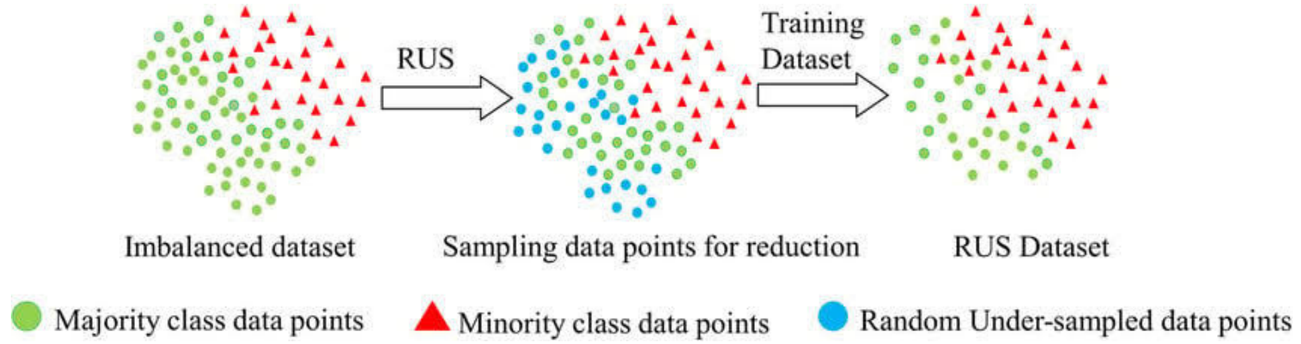
NCR (**Neighbourhood Cleaning Rule**) merupakan metode **pengembangan dari Edited Nearest Neighbours** (**ENN**) **yang digunakan untuk menghapus data yang bising** (**noise**). Metode ini bekerja dengan melihat tetangga terdekat suatu data, jika suatu data salah diklasifikasikan oleh tetangganya, maka data tersebut dianggap tidak sesuai dan dapat dihapus.



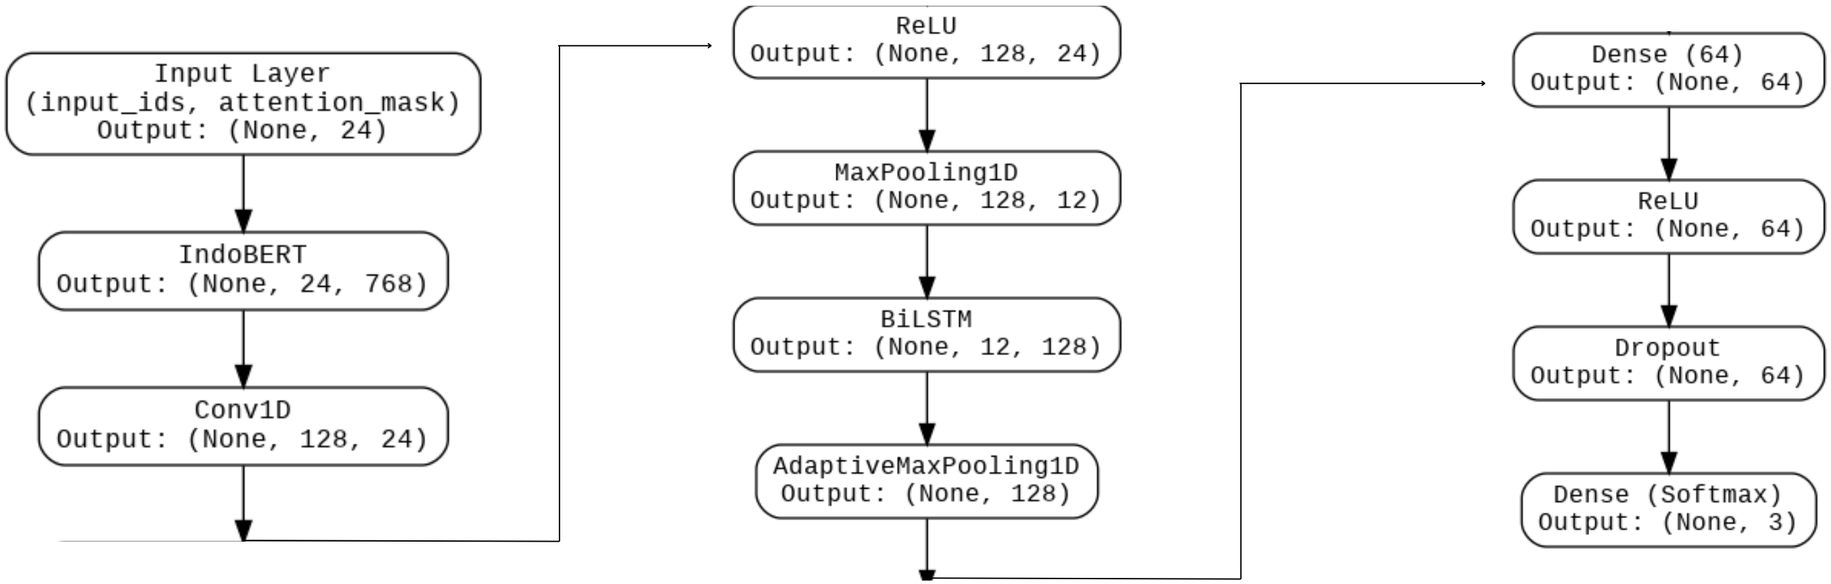
METODE UNDERSAMPLING

RUS (Random Undersampling)

RUS adalah **teknik penyeimbangan data paling dasar dan umum.** Random Undersampling memiliki mekanis penghapusan sampel dari kelas mayoritas secara acak hingga jumlahnya setara dengan kelas minoritas atau dapat ditulis secara eksplisit.



BLOK DIAGRAM MODEL



PERBANDINGAN EVALUASI AKHIR

Metode	Accuracy	Precision	Recall	F1-Score
Hybrid	86.29%	80.47%	80.36%	80.41%
Hybrid + NCR	84.82%	78.59%	81.21%	79.61%
Hybrid + OSS	84.49%	78.36%	80.95%	79.37%
Hybrid + RUS	82.21%	75.71%	80.63%	77.43%
Hybrid + OSS + RUS	81.64%	75.43%	80.79%	77.14%
Hybrid + NCR + RUS	81.15%	75.17%	81.17%	76.96%

PERBANDINGAN AUC-ROC

Metode	AUC-ROC
Hybrid	90.79%
Hybrid + NCR	91.62%
Hybrid + OSS	91.37%
Hybrid + RUS	90.98%
Hybrid + OSS + RUS	89.91%
Hybrid + NCR + RUS	90.23%

RASIO PERBANDINGAN DATA METODE TERBAIK

METODE *HYBRID* GABUNGAN INDOBERT-CNN-BILSTM

	Data Train	Data Validation	Data Test
Negatif	76%	4%	20%
Netral	76%	4%	20%
Positif	76%	4%	20%

- Pembagian rasio ini **diterapkan pada Metode Hybrid gabungan IndoBERT-CNN-BiLSTM tanpa penambahan teknik undersampling** dan terbukti menghasilkan akurasi dan F1-Score paling baik.
- Dataset dibagi dengan rasio **76% untuk Data Train, 4% untuk Data Validation, dan 20% untuk Data Test.**
- Rasio **pembagian** ini diterapkan **secara merata dan konsisten pada ketiga kelas** sentimen, yaitu Negatif, Netral, maupun Positif.

CONFUSION MATRIX METODE TERBAIK

METODE *HYBRID* GABUNGAN INDOBERT-CNN-BILSTM

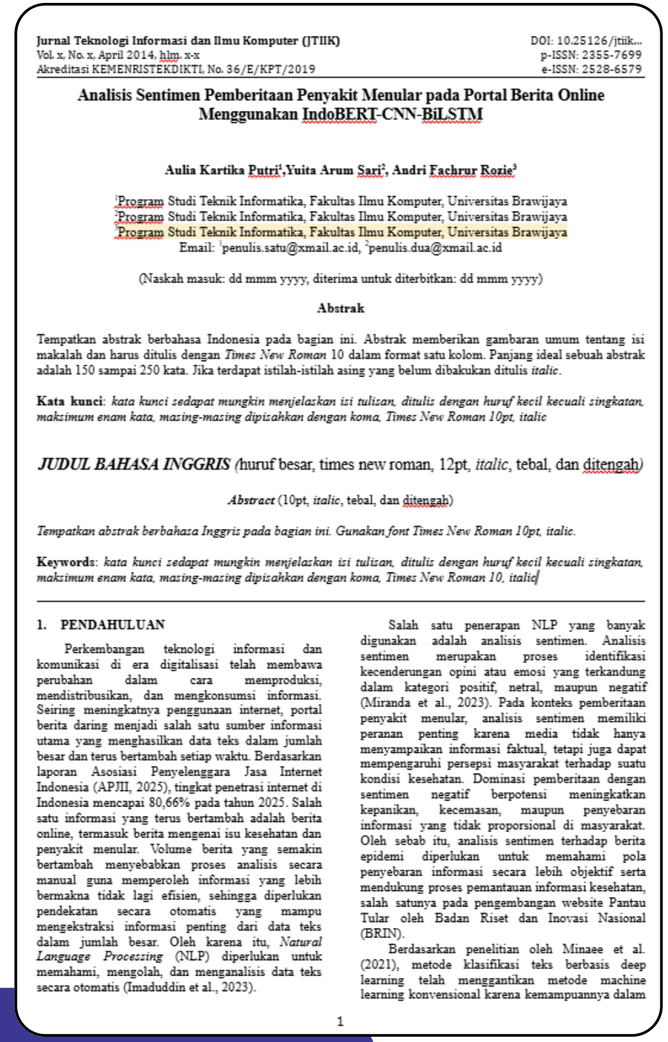
	Precision	Recall	F1-Score	Support
-1	0.91	0.91	0.91	10864
0	0.63	0.61	0.62	2588
1	0.88	0.89	0.88	3992

IMPLEMENTASI METODE TERBAIK

Inputan	Hasil	Probabilitas
Kasus sembuh dari COVID-19 tambah 152, kasus positif tambah 278 orang	Netral	91.75%
Kemkes: 67 dari 69 WNI ABK Diamond Princess negatif COVID-19	Positif	99.66%
Satu pasien positif COVID-19 di Kota Kediri meninggal	Negatif	99.53%

KESIMPULAN

- **Model gabungan IndoBERT–CNN–BiLSTM tanpa teknik undersampling memberikan hasil paling optimal** dengan tingkat akurasi mencapai 86.29% dan F1-Score 80.41%.
- **Distribusi kelas pada dataset** (Negatif 62.3%, Netral 14.8%, dan Positif 22.9%) dalam konteks penelitian ini **belum bisa dikatakan imbalance**. Model terbukti sudah cukup robust untuk mempelajari pola dari data asli tersebut.
- **Penerapan metode undersampling** (**NCR, OSS, dan RUS**) **justru menurunkan kinerja model.** Hal ini dikarenakan pemangkasan data pada kelas mayoritas (Negatif) menyebabkan model kehilangan terlalu banyak informasi yang krusial untuk proses pelatihan deep learning.
- **Penggunaan teknik undersampling pada kasus ini dinilai tidak efektif**. Model hybrid terbukti sudah beroperasi secara optimal tanpa perlu tambahan teknik penyeimbangan data.



Jurnal Teknologi Informasi dan Ilmu Komputer (JTIIK)
Vol. x, No. x, April 2014, hlm. x-x
Akreditasi KEMENRISTEKDIKTI, No. 36/E/KPT/2019

DOI: 10.25126/jtiik...
p-ISSN: 2355-7699
e-ISSN: 2528-6579

Analisis Sentimen Pemberitaan Penyakit Menular pada Portal Berita Online Menggunakan IndoBERT-CNN-BiLSTM

Aulia Kartika Putri[1],Yuita Arum Sari[2], Andri Fachrur Rozie[3]

[1]Program Studi Teknik Informatika, Fakultas Ilmu Komputer, Universitas Brawijaya
[2]Program Studi Teknik Informatika, Fakultas Ilmu Komputer, Universitas Brawijaya
[3]Program Studi Teknik Informatika, Fakultas Ilmu Komputer, Universitas Brawijaya
Email: [1]penulis.satu@xmail.ac.id, [2]penulis.dua@xmail.ac.id

(Naskah masuk: dd mmm yyyy, diterima untuk diterbitkan: dd mmm yyyy)

Abstrak

Tempatkan abstrak berbahasa Indonesia pada bagian ini. Abstrak memberikan gambaran umum tentang isi makalah dan harus ditulis dengan *Times New Roman* 10 dalam format satu kolom. Panjang ideal sebuah abstrak adalah 150 sampai 250 kata. Jika terdapat istilah-istilah asing yang belum dibakukan ditulis *italic*.

Kata kunci: *kata kunci sedapat mungkin menjelaskan isi tulisan, ditulis dengan huruf kecil kecuali singkatan, maksimum enam kata, masing-masing dipisahkan dengan koma, Times New Roman 10pt, italic*

JUDUL BAHASA INGGRIS (huruf besar, times new roman, 12pt, *italic*, tebal, dan ditengah)

Abstract (10pt, *italic*, tebal, dan ditengah)

Tempatkan abstrak berbahasa Inggris pada bagian ini. Gunakan font Times New Roman 10pt, italic.

Keywords: *kata kunci sedapat mungkin menjelaskan isi tulisan, ditulis dengan huruf kecil kecuali singkatan, maksimum enam kata, masing-masing dipisahkan dengan koma, Times New Roman 10, italic*

1. PENDAHULUAN

Perkembangan teknologi informasi dan komunikasi di era digitalisasi telah membawa perubahan dalam cara memproduksi, mendistribusikan, dan mengkonsumsi informasi. Seiring meningkatnya penggunaan internet, portal berita daring menjadi salah satu sumber informasi utama yang menghasilkan data teks dalam jumlah besar dan terus bertambah setiap waktu. Berdasarkan laporan Asosiasi Penyelenggara Jasa Internet Indonesia (APJII, 2025), tingkat penetrasi internet di Indonesia mencapai 80,66% pada tahun 2025. Salah satu informasi yang terus bertambah adalah berita online, termasuk berita mengenai isu kesehatan dan penyakit menular. Volume berita yang semakin bertambah menyebabkan proses analisis secara manual guna memperoleh informasi yang lebih bermakna tidak lagi efisien, sehingga diperlukan pendekatan secara otomatis yang mampu mengekstraksi informasi penting dari data teks dalam jumlah besar. Oleh karena itu, *Natural Language Processing* (NLP) diperlukan untuk memahami, mengolah, dan menganalisis data teks secara otomatis (Imaduddin et al., 2023).

Salah satu penerapan NLP yang banyak digunakan adalah analisis sentimen. Analisis sentimen merupakan proses identifikasi kecenderungan opini atau emosi yang terkandung dalam kategori positif, netral, maupun negatif (Miranda et al., 2023). Pada konteks pemberitaan penyakit menular, analisis sentimen memiliki peranan penting karena media tidak hanya menyampaikan informasi faktual, tetapi juga dapat mempengaruhi persepsi masyarakat terhadap suatu kondisi kesehatan. Dominasi pemberitaan dengan sentimen negatif berpotensi meningkatkan kepanikan, kecemasan, maupun penyebaran informasi yang tidak proporsional di masyarakat. Oleh sebab itu, analisis sentimen terhadap berita epidemi diperlukan untuk memahami pola penyebaran informasi secara lebih objektif serta mendukung proses pemantauan informasi kesehatan, salah satunya pada pengembangan website Pantau Tular oleh Badan Riset dan Inovasi Nasional (BRIN).

Berdasarkan penelitian oleh Minaee et al. (2021), metode klasifikasi teks berbasis deep learning telah menggantikan metode machine learning konvensional karena kemampuannya dalam





TERIMA KASIH